

Virtual Human 에이전트를 활용한 가상면접 플랫폼



팀명: VRoom

202155575 유재명

202055503 강동요

202355503 강저릭 어요솅드

지도교수: 이명호

제출일: 2026년 9월 14일

부산대학교

목차

1	프로젝트 배경 및 목표	1
1.1	프로젝트 배경 및 필요성	1
1.2	프로젝트 목표	1
1.3	관련 연구	2
2	설계 요구사항 및 제약	3
2.1	초기 기능적 요구사항	3
2.2	초기 비기능적 요구사항	4
2.3	초기 제약사항	4
2.4	요구사항 대비 구현 현황	5
3	개발 과정의 문제점 및 대응	7
3.1	구현 중 추가로 발견된 제약	7
3.2	기존 요구사항의 문제점	7
3.3	변경·수정된 요구사항	8
3.4	문제 해결을 위한 대처사항	9
4	프로젝트 구조	11
4.1	전체 구조 개요	12
4.2	Unity 클라이언트	14
4.3	오디오 처리 파이프라인	14
4.4	AI 및 백엔드	15
4.4.1	면접관 페르소나와 행동 패킷	16
4.4.2	한 턴의 입력·처리·출력	18
4.5	멀티모달 분석 및 피드백	20
4.5.1	음성 분석	20
4.5.2	웹캠 기반 행동 분석	20

4.5.3	개입 판정과 처리	23
4.5.4	통합 점수 및 피드백 생성	24
5	구현 결과 및 시연	27
5.1	최종 면접 진행 과정	27
5.2	동적 페르소나 및 면접관 반응	27
5.3	음성·영상 기반 피드백	28
5.4	시스템 실행 방법	29
5.4.1	실행 하드웨어와 모델 설정	29
5.4.2	환경 및 모델 준비	30
5.4.3	환경 변수 설정	30
5.4.4	Docker 워커 실행	31
5.4.5	Webcam 분석 워커 실행	31
5.4.6	Python 백엔드 실행	32
5.4.7	Unity 클라이언트 연결	32
5.5	음성 처리 지연 측정 결과	32
5.6	STT 전사 성능 참고 측정	33
6	성능 평가 및 실험 분석	36
6.1	평가 개요와 실험 설계	36
6.1.1	평가 목적과 평가 기준	36
6.1.2	실험 설계	37
6.1.3	표준화된 답변 프로토콜	37
6.1.4	측정 환경	38
6.1.5	세션 선별과 데이터 규모	38
6.1.6	분석 방법	39
6.2	응답 지연 성능 평가	39
6.2.1	측정 구간의 정의	39
6.2.2	구간별 측정 결과	40
6.2.3	발화 길이에 따른 지연 증가	40
6.2.4	기존 측정치와의 관계	41
6.2.5	목표 대비 달성도와 개선 방향	42
6.3	문장 단위 스트리밍의 지연 개선 효과	42
6.3.1	비교 설계와 TTS 합성 성능	42

6.3.2	개선 효과	43
6.3.3	개입 경로의 2발화 분리 효과	43
6.4	음성 인식 성능 평가	44
6.4.1	평가 프로토콜과 문자 오류율	44
6.4.2	전문 용어 인식률	45
6.4.3	오류 유형과 하류 영향	46
6.5	음성 피쳐 성능 평가	46
6.6	영상 피쳐 성능 평가	47
6.6.1	검출 및 처리 성능	47
6.6.2	시선 피쳐의 참가자 간 체계적 편향	48
6.6.3	제스처 피쳐의 측정 실패와 표정 피쳐의 포화	48
6.6.4	지속 시간 교란	49
6.7	점수 산정의 타당성 분석	49
6.7.1	검증 설계와 단계별 점수	49
6.7.2	채점 결측률과 점수 해상도	50
6.7.3	평가 항목의 변별력	50
6.7.4	총점의 구성 타당성	51
6.8	면접관 개입의 적절성 평가	51
6.8.1	정답 정의와 게이트 차단 구조	51
6.8.2	긴 답변과 긴 침묵 트리거의 성능	52
6.8.3	주제 이탈 판정기의 성능	53
6.8.4	종단 성능과 미탐 사례	53
6.9	실험 조작 점검	54
6.10	데이터 유효성을 위협한 결함	55
6.10.1	지연 전사 귀속 오류	55
6.10.2	세션 식별자 오염과 결함의 영향 범위	56
6.11	사용자 평가의 부재	56
6.12	평가 결과 종합	57
6.13	한계점의 정량적 근거	58
7	프로젝트 추진 계획	59
7.1	구현 계획	59
7.2	팀원별 역할 분담	60

8 결론 및 향후 계획	61
8.1 최종 구현 결과	61
8.2 한계점	61
8.3 향후 개선 방향	62
A 성능 측정용 대본	63
B LLM 프롬프트 전문	66
B.1 자기소개 정보 추출	66
B.2 면접 턴 생성	66
B.2.1 System 메시지	66
B.2.2 User 메시지	67
B.3 주제 이탈 판정	67
B.4 개입 대사 생성	68
B.5 답변 단독 채점	68
B.6 종료 피드백 생성	68
C 대면 실험 응답 대본	70
D 대면 실험 세션 목록과 결과	75

제1장 프로젝트 배경 및 목표

1.1 프로젝트 배경 및 필요성

면접은 답변 내용과 전달 방식, 시선·자세, 예상하지 못한 질문에 대한 대응을 함께 평가한다. 기존 모의 면접 서비스 중 상당수는 텍스트·음성 질의응답 중심으로 제공되며, 멀티모달 행동 분석을 포함한 연구 시스템도 실제 면접 공간과 질문 흐름에 따른 면접관 반응을 충분히 재현하는 데에는 차이가 있다.

본 과제에서는 PC 환경의 3차원 면접 공간에서 AI 면접관과 대화하는 멀티모달 면접 시뮬레이터를 개발한다. 사용자는 Unity에서 음성으로 답변하고, 시스템은 음성-텍스트 변환(speech-to-text, STT)과 대규모 언어 모델(large language model, LLM)을 이용해 다음 질문을 생성하며 음성·웹캠 피쳐 값을 수집해 종합 피드백을 제공한다. 또한 답변 점수에 따라 면접관의 페르소나와 표정이 변화하고, 주제 이탈·긴 답변·장시간 침묵에는 면접관이 개입하도록 설계하였다.

1.2 프로젝트 목표

본 과제의 목표는 다음과 같다.

1. PC 화면에서 실제 면접과 유사한 3차원 공간과 상호작용을 제공하는 Unity 클라이언트를 구현한다.
2. 음성을 STT로 변환하고 LLM으로 답변을 평가하여 다음 질문과 면접관 대사를 생성한다.
3. 답변 점수에 따라 면접관의 긍정·중립·부정 페르소나와 표정이 변화하도록 구현한다.
4. 음성·웹캠 피쳐 값을 수집하여 시선, 자세, 제스처, 표정, 음량, 속도, 답변 길이, 추임새, 답변 품질, 반응 시간을 평가한다.
5. 주제 이탈, 긴 답변, 장시간 침묵에 면접관이 개입하고 개입 전후의 대화와 분석 정보를 기록한다.

1.3 관련 연구

멀티모달 면접 훈련 시스템의 선행 사례로 Hoque et al.의 MACH(My Automated Conversation coach)를 참고할 수 있다. MACH는 가상 에이전트가 사용자의 얼굴 표정, 음성 및 운율을 분석하고, 실시간으로 언어·비언어적 반응을 생성하며, 면접 후 시각적 피드백을 제공하는 시스템이다[5]. 또한 실제 사용자를 대상으로 시스템의 면접 훈련 효과를 평가하여, 멀티모달 분석과 피드백을 결합한 면접 훈련 시스템의 가능성을 제시하였다.

Adiani et al.은 Career Interview Readiness in Virtual Reality(CIRVR)를 제안하였다. CIRVR은 가상 면접 환경, 대화 관리 모듈, 시선·표정·생리 신호 분석 모듈 및 결과 대시보드로 구성되며, 수집된 행동 정보를 이용해 개인화된 면접 훈련을 지원한다[1]. 이 연구는 본 과제와 마찬가지로 가상 면접관과 멀티모달 분석을 결합하지만, VR 기반 환경과 생리 신호를 포함한다는 점에서 본 과제의 PC 기반 웹캠·음성 분석 구조와 차이가 있다.

상용 서비스 사례로는 Yoodli가 있다. Yoodli는 입력한 직무와 기업 정보를 바탕으로 면접 질문과 후속 질문을 생성하고, 면접 후 발화 속도와 추임새 등을 포함한 분석 결과를 제공한다[13]. 다만 상용 서비스의 공개 자료만으로는 내부 모델과 점수 산정 방식을 확인하기 어렵기 때문에, 본 보고서에서는 기능 비교를 위한 사례로만 활용한다.

대화 시스템의 턴 교체 지연에 관한 연구로 Skantze의 연구를 참고하였다. 해당 연구는 인간 대화에서 짧은 턴 교체 공백이 나타나는 반면, 대화 시스템에서는 긴 응답 지연이 대화 흐름을 저해할 수 있음을 정리한다[12].

이러한 선행 사례를 고려하면 본 과제의 차별점은 멀티모달 분석 자체에 있지 않다. 본 과제는 PC 기반 Unity 면접 환경에서 한국어 기술 면접을 수행하고, 자기소개에서 추출한 기업·직무·기술 정보를 LLM 질문 생성에 반영하며, 답변 점수에 따른 면접관 페르소나 변화와 주제 이탈·긴 답변·긴 침묵에 대한 실시간 개입을 하나의 면접 흐름으로 통합하는 데 초점을 둔다.

제2장 설계 요구사항 및 제약

2.1 초기 기능적 요구사항

착수보고서에서는 사용자가 실제 면접과 유사한 환경에서 대화하고, 답변 내용과 비언어적 행동을 함께 평가받을 수 있도록 다음의 기능을 핵심 요구사항으로 정의하였다.

1. Unity 엔진을 이용하여 실제 면접장과 유사한 3차원 VR 면접 공간을 제공해야 한다.
2. 사실적인 Virtual Human 면접관을 구현하고, 합성 음성과 면접관의 입 모양을 실시간으로 동기화해야 한다.
3. 사용자가 지원 기업, 지원 직무, 이력서 정보를 입력하고 직무에 맞는 면접을 시작할 수 있어야 한다.
4. 시스템은 자기소개, 기술 질문, 꼬리질문, 인성 질문, 마무리 질문으로 구성된 면접 흐름을 제공해야 한다.
5. 사용자의 음성을 실시간으로 수집하고 STT를 통해 텍스트로 변환해야 하며, 발화의 종료와 일시적인 침묵을 구분해야 한다.
6. 음성 크기, 발화 속도, 답변 길이와 같은 음성 피쳐 값과 시선, 자세, 제스처, 표정과 같은 비언어적 피쳐 값을 수집해야 한다.
7. LLM은 현재 면접 단계, 지원 직무, 이전 답변 기록과 추출된 피쳐 값을 참고하여 답변을 채점하고 다음 질문과 꼬리질문을 생성해야 한다.
8. 사용자의 답변에 따라 직무에 맞춘 면접관 페르소나와 반응을 제공해야 한다.
9. 면접 종료 후 답변의 논리성, 직무 적합성, 답변 구성 및 비언어적 행동을 종합하여 피드백 데이터를 생성해야 한다.

2.2 초기 비기능적 요구사항

기능 구현뿐만 아니라 실제 사람과 대화하는 듯한 상호작용을 제공하기 위해 다음의 비기능적 요구사항을 설정하였다. 초기 단계에서는 응답 지연을 실시간 대화가 가능한 수준으로만 정의하고, 구체적인 수치 목표는 설정하지 못하였다.

- **낮은 응답 지연:** 발화 종료부터 다음 질문의 음성 재생까지의 왕복 지연 시간(round-trip time, RTT)을 실시간 대화가 가능한 수준으로 줄여야 한다.
- **높은 STT 정확도:** 일반적인 실사용 환경의 소음에서도 LLM이 이해할 수 있는 수준의 전사 결과를 제공해야 한다.
- **적절한 침묵 감지:** 사용자가 생각하는 짧은 침묵을 답변 종료로 오인하지 않으면서 실제 발화 종료는 빠르게 감지해야 한다.
- **개인정보 보호:** 이력서와 답변에 포함된 개인정보가 외부 LLM으로 전송될 수 있음을 고려하여 데이터 처리 방침과 동의 절차를 마련해야 한다.
- **안정성:** STT, 텍스트-음성 변환(text-to-speech, TTS), 웹캠 분석 워커 중 하나가 연결되지 않더라도 가능한 기능을 유지해야 한다.
- **확장성:** Unity 클라이언트와 각 처리 서버를 분리하여 다른 음성 모델이나 분석 모델로 교체할 수 있어야 한다.
- **실행환경 분리:** 각 AI 모델이 요구하는 프레임워크와 CUDA 라이브러리 환경을 Docker 컨테이너별로 분리하여 라이브러리 충돌을 방지해야 한다.
- **기록성:** 세션별 대화 기록, 음성·영상 피쳐 값과 주요 처리 상태를 저장하여 편집 결과를 확인할 수 있어야 한다.

2.3 초기 제약사항

초기 설계에서 예상한 현실적 제약사항은 다음과 같다.

1. 멀티모달 데이터를 매 프레임 전송하면 CPU 연산량과 네트워크 대역폭이 증가할 수 있다.
2. STT·LLM·TTS를 순차 호출하면 실시간 응답을 만족하기 어렵다.
3. STT와 TTS의 실시간 실행에는 GPU 자원과 충분한 메모리가 필요하다.

4. 모듈을 분산 실행하면 네트워크 지연과 연결 실패가 발생할 수 있다.
5. 이력서와 답변을 외부 LLM으로 전송할 때 개인정보 보호 문제가 발생할 수 있다.
6. 장시간 면접에서는 문맥 증가에 따른 토큰 제한과 API 비용 문제가 발생할 수 있다.
7. LLM 질문과 대사의 품질이 프롬프트, 대화 문맥, 외부 API 응답에 따라 달라질 수 있다.

2.4 요구사항 대비 구현 현황

초기 요구사항을 기준으로 최종 구현 상태를 충족, 부분 충족, 변경 및 미흡으로 구분하였다. 세부 현황은 표 2.1과 같다.

표 2.1: 요구사항 대비 구현 현황

구분	초기 요구사항	구현 상태	비고
기능	Unity 기반 3차원 VR 면접 공간	변경	VR 장비 기반에서 PC 기반 Unity 3차원 면접 환경으로 변경
기능	Virtual Human 면접관 및 실시간 립싱크	부분 충족	Virtual Human과 uLipSync 립싱크를 구현하였으나, 표정·제스처 종류는 제한적
기능	기업·직무·이력서 정보 입력	충족	자기소개 및 지원 정보를 구조화하여 면접 생성에 활용
기능	자기소개·기술·꼬리·인성·마무리 면접 흐름	충족	면접 단계별 지시문과 턴 생성 로직 구현
기능	음성 수집·STT·발화 종료 감지	부분 충족	STT와 VAD를 구현하였으나 부분 전사 정확도와 종료 지연에 한계
기능	음성·시각 피쳐 값 수집	부분 충족	음성 6개와 영상 4개 평가 항목을 수집하고 점수화
기능	LLM 기반 답변 채점 및 질문 생성	충족	답변 점수와 채점 근거, 다음 질문 및 꼬리 질문 생성
기능	답변에 따른 면접관 페르소나 변화	부분 충족	점수 기반 페르소나와 표정 변화를 구현하였으나 제스처 표현은 제한적
기능	면접 종료 후 종합 피드백 생성	충족	항목별 점수, 강점, 개선점 및 총평 생성

구분	초기 요구사항	구현 상태	비고
비기능	낮은 응답 지연	부분 충족	지연 측정은 수행하였으나 파이프라인 최적화는 미흡
비기능	높은 STT 정확도	부분 충족	일반 발화는 처리 가능하나 전문 용어 인식 정확도가 낮음
비기능	적절한 침묵 감지	부분 충족	침묵 임계값 기반 VAD를 구현하였으나 턴별 종료 지연 편차가 존재
비기능	개인정보 보호	부분 충족	원시 음성·영상은 로컬 워커에서 처리하고 세션 JSON에 저장하지 않지만, 전사·이력서 관련 정보는 외부 LLM API로 전송될 수 있으며 로그 보존·삭제·접근 통제 정책은 보완 필요
비기능	모듈 장애 상황의 안정성	부분 충족	웹캠 워커 미연결 시 음성 면접으로 진행 가능
비기능	모델 교체를 고려한 확장성	충족	Unity, 백엔드, STT·TTS 워커를 분리하여 구성
비기능	Docker 기반 실행환경 분리	충족	STT·TTS 모델별 Docker 실행환경 구성
비기능	세션 및 분석 결과 기록	충족	대화 기록, 턴 정보, 음성·영상 피쳐 값 저장

제3장 개발 과정의 문제점 및 대응

3.1 구현 중 추가로 발견된 제약

구현이 진행되면서 Unity 클라이언트, AI 백엔드, STT 워커, TTS 워커를 각각 실행하는 구조가 구체화되었다. 각 모듈은 담당 기능을 분리할 수 있다는 장점이 있었지만, 모듈마다 실행 시점과 메시지 형식이 달랐고 면접 단계나 발화 상태를 여러 모듈이 중복해서 관리하고 있었다. 그 결과 발화의 시작·종료와 면접 단계가 서로 어긋나지 않도록 상태를 정리하고 동기화하는 작업이 필요했다. 특히 음성 처리가 완료되기 전에 다음 질문이 생성되거나, 이전 발화에 대한 늦은 전사 결과가 다음 턴에 섞이지 않도록 세션 ID와 발화 ID를 메시지에 포함해야 했다.

웹캠 분석을 추가하면서 영상 자체를 Unity와 백엔드 사이에서 계속 전달하는 방식도 적합하지 않다는 점이 드러났다. 현재 구현에서는 웹캠 분석 워커가 카메라를 로컬에서 읽고, Unity는 캘리브레이션과 턴 경계만 워커에 전달한다. 따라서 전송량은 줄었지만, Unity의 면접 상태와 워커의 분석 구간을 동일하게 유지해야 하는 동기화 문제가 새롭게 생겼다. 개입으로 답변이 중단되는 경우에는 일반 턴과 구분되는 TRUNCATED, REACTION, REANSWER 위상을 사용하여 분석 구간을 나누도록 처리하였다.

또 다른 제약은 첫 질문과 모델 초기화에서 발생하는 초기 지연이었다. 첫 질문까지 LLM과 음성 합성을 모두 거치면 면접 시작 직후의 대기 시간이 커질 수 있으므로, 첫 질문은 현재 템플릿으로 생성하고 서버 준비 단계에서 필요한 모델과 연결을 미리 초기화하도록 조정하였다.

3.2 기존 요구사항의 문제점

초기 요구사항은 STT 전사, LLM 기반 질문·평가, TTS 응답이 하나의 음성 대화 흐름으로 이어지는 것을 전제로 하였다. 그러나 고정된 처리 순서와 한 번에 결과를 전달하는 방식만으로는 면접 시작 직후와 다음 질문 생성 시 대기 시간이 길어질 수 있었다. 이에 첫 질문을 템플릿으로 처리하고, TTS 결과는 생성되는 오디오 청크부터 스트리밍하도록 요구

사항을 구체화하였다.

착수 단계에서는 XTTS-v2[3]를 TTS 모델로 사용할 계획이었으나, 실제 한국어 면접 대사를 생성하는 과정에서 음성 품질이 낮고 발음이 부자연스러운 문제가 확인되었다. 이에 한국어 음성 데이터 학습량이 상대적으로 많은 Fish Speech[7]를 검토하였고, 동일한 면접 대사를 생성했을 때 한국어 발음과 음질이 더 적합하다고 판단하여 TTS 모델을 Fish Speech 1.5로 변경하였다. 이 변경에 따라 TTS 워커의 모델 초기화 및 음성 생성 코드도 함께 수정하였다.

음성 입력의 종료를 고정된 침묵 시간만으로 결정하는 방식도 실제 사용 흐름과 맞지 않았다. 사용자가 문장을 끝냈더라도 짧은 침묵이 들어갈 수 있고, 반대로 아직 답변 중인데 긴 호흡이나 생각 시간이 발생할 수도 있기 때문이다. 현재는 Unity의 VAD가 발화 상태와 오디오 청크를 관리한다. STT 워커는 음성을 전사하면서 문장이 끝났다고 판단되면 Unity에 신호를 보내 침묵 임계값을 줄이고, 개입 판단에 사용할 부분 전사를 백엔드로 보낸다. 최종 답변의 종료와 개입 판단용 부분 전사는 서로 영향을 주지 않도록 별도로 처리하였다.

초기 설계에서는 LLM이 답변 점수와 함께 면접관의 표정과 태도까지 직접 선택하도록 구성할 수 있었다. 그러나 동일한 점수의 답변에도 LLM이 서로 다른 표정이나 태도를 선택할 수 있어, 점수와 면접관 반응 사이의 규칙을 일관되게 유지하기 어려웠다. 따라서 현재는 LLM이 답변 대사와 점수를 생성하고, 백엔드가 점수 구간에 따라 면접관의 페르소나를 결정한다. 이후 해당 페르소나에서 허용된 표정만 적용하여 점수와 면접관 반응의 관계가 일정하게 유지되도록 하였다. 또한 LLM 응답의 파싱 실패에 대비해 재시도와 기본 응답을 두어 대화 흐름이 중단되지 않도록 하였다.

3.3 변경 · 수정된 요구사항

중간보고서와 이후 구현 내역을 기준으로 실제 변경된 요구사항은 다음과 같다.

- 머리 착용형 디스플레이(head-mounted display, HMD) 기반 VR 면접 환경에서 PC 기반 3차원 면접 환경으로 변경하고, HMD 입력 대신 웹캠을 이용한 행동 데이터 수집을 추가한다.
- 한국어 음성 품질 문제로 착수 단계에서 계획한 XTTS-v2 대신 Fish Speech 1.5를 사용하는 TTS 워커로 변경한다.
- STT와 TTS를 독립 워커로 운영하고, Unity-STT-TTS 사이의 음성 및 자막 전달을 지속적인 WebSocket 연결로 처리한다.

- LLM 호출과 대화 문장 분할을 음성 워커가 아닌 AI 백엔드의 세션 로직에서 담당하도록 변경한다.
- STT는 Whisper 계열 모델을 CUDA FLOAT16 설정으로 실행한다. 발화 식별자와 문장 단위 체크포인트도 사용한다.
- 첫 질문은 템플릿으로 생성하고, 서버 준비 단계에서 초기화와 워업을 수행하여 시작 시 지연을 줄인다.
- 사용자의 마지막 음성 프레임부터 Unity의 첫 음성 재생까지의 응답 지연을 최대 2s 이내로 제한하는 정량 평가 기준을 적용한다[12].
- LLM 출력은 답변 대사, 점수, 채점 근거와 표정 ID를 포함하는 단일 JSON 계약으로 제한하고, 페르소나와 면접 단계 전이는 백엔드 코드가 관리한다.
- 웹캠 분석 워커가 카메라를 로컬에서 처리하며, Unity와는 캘리브레이션 및 턴 시작·종료 정보를 교환한다.
- 주제 이탈, 긴 답변, 긴 무응답에 대응하는 면접관 개입을 추가하고, 개입 대사와 후속 질문을 분리한다.
- 개입이 발생한 발화에는 일반 답변, 잘린 답변, 개입 직후 반응, 재답변을 구분하는 턴 위상을 적용한다.

3.4 문제 해결을 위한 대처사항

기능별 책임을 분리하기 위해 Unity는 화면, 면접관 연출, 마이크 입력, 오디오 재생과 턴 상태를 담당하고, STT·TTS 워커는 각각 전사와 Fish Speech 기반 음성 합성을 담당하도록 구성하였다. AI 백엔드는 세션, 면접 단계, 대화 기록, 점수와 페르소나를 관리하며, 각 메시지에 세션 ID와 발화 ID를 포함해 지연된 메시지가 다른 턴에 적용되지 않도록 하였다.

Unity의 VAD는 발화 시작·종료와 오디오 청크를 관리하고, STT 워커는 부분 전사와 최종 전사를 전달한다. 최종 발화의 전사와 음성 피쳐 값은 백엔드의 점수·피드백 계산에 사용하며, TTS 응답은 자막, 오디오 청크, 종료 메시지로 나누어 Unity가 재생 종료를 관리하도록 하였다.

개입 대사가 재생되는 동안에는 사용자의 추가 발화는 일반적인 답변으로 STT에 전송하지 않고, 일정 시간안에 응답이나 후속 질문이 도착하지 않으면 타임아웃을 발생시켜 다시 사용자의 답변을 받을 수 있도록 하였다. 개입이 확정된 뒤에는 이전 발화에 대해 진행 중이던

STT 결과를 무효화하여, 늦게 도착한 전사 결과가 다음 면접 단계에 잘못 반영되지 않도록 하였다.

웹캠 워커가 연결되지 않으면 시각 피쳐 값만 제외하고 음성 면접은 계속한다. 연결된 경우에는 특별 시각 피쳐를 기록하며, 개입으로 중단된 구간은 일반 답변과 구분해 처리한다.

제4장 프로젝트 구조

기호표

4장에서 사용하는 수식의 주요 기호와 의미를 표 4.1에 정리하였다. 점수 기호는 별도의 언급이 없는 한 0 ~ 10 또는 0 ~ 100 범위를 따른다.

표 4.1: 4장 주요 수식 기호표

기호	의미	사용 맥락
s	LLM이 산출한 답변 점수	페르소나 및 연속 제어값 계산
l	낮은 점수 답변의 연속 횟수	연속 제어값 v 의 보정
v	Animator에 전달되는 연속 제어값	자세·발화 애니메이션의 긍정·부정 방향
N_{text}	전사된 문자 수	발화 속도 계산
t_{speech}	순수 발화 시간	발화 속도 및 답변 길이 계산
c	초당 문자 수	전사 문자 수를 발화 시간으로 나눈 값
r	평균 음량	음량 점수 계산
σ^2	음량 분산	음량 변동성 감점 계산
ρ_{low}	낮은 음량 구간의 비율	작은 음량 구간 감점 계산
p	의미 있는 침묵 횟수	발화 속도 점수 감점
$S_{\text{volume}}, S_{\text{speed}}$	음량·발화 속도 점수	음성 피쳐 점수
$S_{\text{length}}, S_{\text{response}}$	답변 길이·반응 시간 점수	음성 피쳐 점수
t, r_t, μ_t	발화 시간, 반응 시간, 목표 반응 시간	답변 길이 및 반응 시간 점수
f_{vision}	웹캠 분석 프레임률	영상 분석 실행 조건

기호	의미	사용 맥락
$(W, H), t_{\text{calibration}}$	카메라 해상도, 캘리브레이션 시간	웹캠 분석 실행 조건
$N_{\text{target}}, N_{\text{face}}$	정면 응시 프레임 수, 얼굴 검출 프레임 수	시선 비율 계산
$r_g, \dot{j}_g$	정면 응시 비율, 머리 흔들림 크기	시선 점수 계산
$\sigma_{\text{yaw}}, \sigma_{\text{pitch}}$	머리 yaw · pitch의 표준편차	머리 흔들림 크기 계산
τ, σ_b	어깨 기울기, 상체 흔들림	자세 점수 계산
u, e, F	손 사용 비율, 손 동작 범위, 얼굴 접촉 횟수	제스처 점수 계산
v_e, r_f, r_s	표정 변화량, 찡그림 비율, 미소 비율	표정 점수 계산
$N_{\text{frame}}, N_{\text{pose}}$	전체 프레임 수, 자세 검출 프레임 수	영상 피쳐 채점 가능 여부
$N_{\text{max}}, N_{\text{partial}}$	최대 개입 횟수, 부분 전사 문자 기준	개입 판정 조건
T_{cooldown}	개입 사이의 유예 시간	개입 판정 조건
$T_{\text{long}}, T_{\text{silence}}$	긴 답변 · 침묵의 기준 시간	길이 · 침묵형 개입
T_{grace}	주제 이탈 판정 유예 시간	부분 전사 기반 개입 판정
$\Delta t_{\text{checkpoint}}$	부분 전사 체크포인트 주기	부분 전사 기반 개입 판정

4.1 전체 구조 개요

VRoom은 Unity 클라이언트, AI 백엔드, STT 워커, TTS 워커, 웹캠 분석 워커로 구성된다. Unity 클라이언트는 PC 기반 3차원 면접 공간과 사용자 인터페이스, 면접관 캐릭터, 마이크 입력 및 음성 재생을 담당한다. AI 백엔드는 면접 세션과 대화 상태를 관리하고 LLM을 호출하여 답변 채점과 다음 질문 생성을 수행한다. STT와 TTS는 GPU 자원을 사용하는 독립 워커로 분리하여 모델 실행 환경과 서비스 로직을 분리하였다.

한 턴의 기본 데이터 흐름은 다음과 같다. 사용자가 Unity에서 말하면 STT 워커가 음성을 텍스트로 변환한다. 변환된 텍스트는 백엔드로 전달되고, 백엔드는 현재 단계와 대화 기록을 바탕으로 답변을 채점하고 다음 질문을 생성한다. 생성된 행동 패킷은 Unity로 전송되어 자




그림 4.1: VRoom 전체 시스템 구조

표 4.2: VRoom 주요 구성 요소

구성 요소	주요 역할
Unity 클라이언트	PC 기반 3차원 면접 공간, 설정 화면, 면접관 연출, 음성 입력·재생, 결과 화면
AI 백엔드	세션 상태, 면접 단계, LLM 호출, 점수·페르소나 결정, 피드백 생성
STT 워커	음성 입력의 부분 전사 및 최종 전사, 음성 종료 판단
TTS 워커	면접관 대사를 음성으로 합성하고 스트리밍
웹캠 분석 워커	턴별 웹캠 프레임 분석 및 시각 피쳐 값 집계

막, 표정, 페르소나에 반영된다. 동시에 질문 대사는 TTS 워커로 전달되어 음성으로 합성된 후 Unity에서 재생된다.

4.2 Unity 클라이언트

Unity 클라이언트는 설정 화면, 면접 화면, 결과 화면으로 구성된다. 설정 화면에서는 회사명, 직무, 이력서 등의 정보를 입력하고 면접 세션을 준비한다. 면접 화면에서는 가상 면접관과 면접 공간을 표시하며, PipelineController가 대기, 면접관 발화, 사용자 답변, 개입, 종료 상태를 관리한다.

백엔드에서 전달되는 행동 패킷은 면접 단계, 페르소나, 연속 제어값, 대사, 표정 ID, 답변 점수, 종료 여부를 포함한다. InterviewerDriver는 이 패킷을 받아 면접관의 Animator와 표정 처리 모듈을 구동한다. 연속 제어값은 부정에서 긍정까지의 값으로 Animator의 Emotion 축에 전달하고, 음성 재생 여부는 Speaking 축에 반영한다.

면접관 표정은 BlendShape 프리셋을 이용한다. 긍정, 부정, 중립, 개입 표정을 각각 프리셋으로 저장하고, 전달된 표정 ID에 따라 목표 가중치를 변경한다.

음성 재생 데이터는 단순히 스피커 버퍼로 보내는 것에 그치지 않고 Speaker의 uLipSync 모듈에도 전달된다. uLipSync는 재생 중인 음성의 분석 결과를 이용하여 캐릭터의 입 모양을 갱신하므로, 표정 제어와 음성 기반 입 모양 동기화를 별도의 경로로 처리한다.

4.3 오디오 처리 파이프라인

오디오 파이프라인은 Unity, STT 워커, AI 백엔드, TTS 워커 사이의 양방향 흐름으로 구성된다. 사용자 입력은 Unity에서 모노 펄스 부호 변조(pulse-code modulation, PCM) 형태로 수집되고 음성 활성 탐지 결과에 따라 답변 구간이 결정된다. STT 워커는 Whisper 계열 모델[11]을 기반으로 한 Faster-Whisper 구현을 이용하여 부분 전사와 최종 전사를 수행한다. 문장 종료 여부를 판단하기 위한 전사 경로와 최종 답변을 확정하기 위한 전사 경로를 분리하여, 답변 중간의 정보를 개입 판정에 활용할 수 있도록 하였다. 모듈 사이의 오디오와 텍스트 전달은 WebSocket으로 처리한다.

마이크 입력은 16 kHz, 모노, 16-bit 정수 PCM으로 전달하며 발화 시작 시 WAV 헤더를 포함한다. TTS 워커가 생성하는 음성은 44.1 kHz, 모노, 32-bit 실수 PCM으로 전달한다. 오디오 데이터 형식은 다음과 같다.

면접관 발화는 백엔드가 생성한 대사를 TTS 워커에 전달하여 합성한다. TTS 워커는 Fish Speech 기반 모델을 사용하고, 생성된 오디오를 스트리밍 방식으로 반환한다. 백엔드는 합성된 오디오 청크와 행동 패킷을 Unity로 전달하며, Unity의 Speaker가 버퍼를 관리하여

표 4.3: 오디오 데이터 형식

구분	형식
마이크 입력	16 kHz, Mono, 16-bit Integer PCM (발화 시작 시 WAV 헤더 포함)
음성 출력	44.1 kHz, Mono, 32-bit Float PCM

재생한다. 오디오 재생이 끝난 뒤에 마무리 패킷을 처리하도록 하여, 면접관의 마지막 발화가 끝나기 전에 결과 화면으로 전환되는 문제를 방지한다.

4.4 AI 및 백엔드

AI 백엔드는 FastAPI로 구현하였으며, OpenAI API를 이용해 LLM을 호출한다. 면접 세션마다 현재 단계, 면접관 페르소나, 대화 기록, 단계별 점수, 음성 피쳐 값, 영상 피쳐 값을 저장한다. 면접 단계는 자기소개, 기술 질문, 1차 꼬리질문, 2차 꼬리질문, 인성 질문, 마무리, 종료 순서로 진행된다.

LLM은 면접관 대사, 직전 답변 점수, 채점 근거와 표정 ID를 구조화된 형식으로 반환한다. 페르소나는 LLM의 출력값이 아니라 백엔드가 답변 점수를 기준으로 별도로 결정한다. 답변 점수가 70점 이상이면 긍정, 40점 이상 70점 미만이면 중립, 40점 미만이면 부정 페르소나로 전환한다.

백엔드는 Unity와 /ws/control로 연결되고, STT 워커의 답변 텍스트는 /ws/tts를 통해 수신한다. 텍스트 답변을 직접 처리하기 위한 /process, 웹캠 피쳐 값을 수신하기 위한 /vision, 서버 상태를 확인하기 위한 /health 엔드포인트도 제공한다. 이 구조를 통해 Unity와 음성 처리 모듈을 독립적으로 실행할 수 있다.

LLM 요청에는 회사명, 지원 직무, 경력·기술 정보, 현재 면접 단계, 현재 페르소나, 사용자의 현재 답변, 이전 턴의 대화 기록이 함께 포함된다. 단계별 지시는 자기소개, 기술 질문, 꼬리질문, 인성 질문, 마무리 단계에 따라 달라지며, 모델의 출력은 대사와 점수, 채점 근거, 표정 ID를 포함하는 JSON으로 제한된다. 대화 기록은 별도의 요약이나 최근 턴 절삭 없이 세션에 누적된 턴을 순서대로 결합하는 방식이다. 따라서 현재의 짧은 면접 세션에서는 전체 문맥을 유지하지만, 장시간 세션으로 확장할 때에는 문맥 길이와 API 비용을 관리하는 별도 정책이 필요하다. 실행에 사용한 프롬프트의 전문은 부록 B에 제시하였다.

실제 면접관 대사 생성 요청은 시스템 지시와 사용자 입력으로 구성된다. 시스템 지시에는 기업·직무 정보, 답변 생성 규칙, 단계별 지시와 JSON 출력 규칙이 포함되고, 사용자 입력에는 현재 단계, 현재 페르소나, 직전 답변, 지금까지의 대화 기록과 페르소나별 허용 ID가 포함된다. 다음은 기술 질문 단계에서 사용되는 입력의 축약 예시이다.

```
[APPLICANT INFORMATION]
company: NAVER
job: Backend Developer
experience: Entry-level
skills: Python, FastAPI

[CURRENT_STAGE] TECH_Q1
[CURRENT_PERSONA] NEUTRAL
[USER ANSWER]
I implemented a REST API server with FastAPI.

[DIALOGUE HISTORY]
interviewer(SELF_INTRO): Please introduce yourself.
user(SELF_INTRO): I studied Python backend development.

[OUTPUT RULE]
Return dialogue, score, score_reason and expression_id as JSON only.
```

LLM은 대사, 답변 점수, 채점 근거와 표정 ID를 반환한다. 페르소나는 LLM이 반환하는 필드가 아니며, 백엔드가 답변 점수에 따라 별도로 결정한다.

```
{
  "dialogue": "Please explain how you handled errors.",
  "score": 68,
  "score_reason": "The process was explained, but a concrete example was missing.",
  "expression_id": 3
}
```

대화 기록은 session.turns에 면접관 또는 지원자의 발화를 ‘역할, 면접 단계, 텍스트’ 형태로 저장한 뒤, ‘면접관(STAGE): 내용’ 또는 ‘지원자(STAGE): 내용’ 형식의 텍스트로 순서대로 결합한다. 현재 구현에서는 이 기록을 요약하거나 최근 턴만 남기지 않고 전체를 다음 LLM 요청에 전달한다. 따라서 짧은 면접에서는 문맥을 유지할 수 있지만, 장시간 면접에서는 입력 토큰과 API 비용이 증가할 수 있으며 이를 자동으로 제한하는 정책은 아직 적용하지 않았다.

4.4.1 면접관 페르소나와 행동 패킷

LLM은 답변 점수와 면접관 대사, 표정 ID를 JSON으로 반환한다. 백엔드는 답변 점수에 따라 페르소나를 결정하며, 점수가 70점 이상이면 긍정, 40점 이상 70점 미만이면 중립, 40점 미만이면 부정 페르소나를 사용한다. 페르소나는 다음 LLM 요청에 전달되어 대화 분위기를 지정하고, 조건 C에서는 부정 페르소나일 때만 개입 판정을 통과할 수 있도록 사용된다. 또한 백엔드는 새로 결정된 페르소나에 허용된 표정 ID만 남기도록 LLM의 반환값을 보정한다.

백엔드가 Unity로 보내는 행동 패킷은 다음과 같은 1차원 JSON 구조를 사용한다. 예시는 일반적인 기술 질문에 대한 응답으로, `persona_value`는 답변 점수에서 계산된 Animator 제어값이다.

```
{
  "type": "interviewer_turn",
  "session_id": "session-001",
  "stage": "TECH_Q1",
  "persona": "NEUTRAL",
  "persona_value": 0.36,
  "dialogue": "Please explain why you selected this technology.",
  "expression_id": 3,
  "score": 68,
  "is_final": false,
  "bargain_type": ""
}
```

이 패킷을 수신한 Unity는 `dialogue`를 자막과 TTS 입력으로 사용한다.

`expression_id`에 따라 표정 프리셋을 적용하고, `persona_value`는 Animator의 Emotion 파라미터에 전달한다. `is_final`이 참인 패킷은 면접 종료 후 피드백 화면으로 전환하는 데 사용한다.

`bargain_type`은 개입으로 생성된 패킷인지 구분하기 위한 필드이다.

표 4.4: 점수에 따른 페르소나와 행동 집합

점수 구간	페르소나	허용 표정 ID
70 이상	긍정	따뜻한 미소, 주의 깊은 표정
40 ~ 69	중립	중립, 주의 깊은 표정
40 미만	부정	가벼운 찡그림, 중립

표정 ID는 Unity에서 BlendShape 프리셋을 선택하는 데 사용되며, 선택된 프리셋은 실제 면접관 얼굴에 반영된다.

그림 4.2은 동일한 면접 환경에서 세 가지 표정 프리셋을 적용한 결과이다.

백엔드는 표정 ID와 별도로 답변 점수에서 Animator 제어값을 계산한다. 점수를 s , 40점 미만의 답변이 연속된 횟수를 l 이라 하면, 조건 A이 아니고 채점 대상인 경우의 값 v 는 다음과 같다. 계산 결과는 $[-1, 1]$ 범위로 제한하며, 조건 A이거나 채점 대상이 아닌 경우에는 $v = 0$ 으로 처리한다.

$$v = \max \left(-1, \min \left(1, \frac{s - 50}{50} - 0.2 \min(l, 3) \right) \right)$$

계산된 v 는 행동 패킷의 연속 제어값으로 Unity에 전달된다. Unity는 이를 목표 감정




그림 4.2: 표정 ID에 따른 면접관 페르소나별 표정 비교

값으로 저장한 뒤 Animator의 Emotion 파라미터에 보간하여 적용한다. 이 파라미터는 Speaking 파라미터와 함께 네 개의 자세·발화 애니메이션을 블렌딩한다. 경청 상태에서는 부정·긍정 경청 애니메이션 사이를, 발화 상태에서는 부정·긍정 발화 애니메이션 사이를 긍정·부정 방향으로 보간한다. 따라서 v 는 표정 ID를 선택하는 값이 아니라, 선택된 턴의 자세·발화 애니메이션 방향을 조절하는 값이다.

40점 미만의 답변이 두 번 이상 연속되면 백엔드는 표정 ID를 부정 표정으로 강제한다.

4.4.2 한 턴의 입력·처리·출력

한 턴은 Unity의 발화 감지에서 시작하여 STT 최종 전사, 백엔드 채점·대사 생성, TTS 합성, Unity 재생의 순서로 처리된다. Unity의 음성 활동 감지(voice activity detection, VAD)는 0.3초 간격의 오디오 청크를 STT 워커로 보내고, 발화가 끝났다고 판단하면 최종 전사를 요청한다. STT 워커는 부분 전사를 개입 판단용으로 전달하는 동시에 최종 전사와 음성 처리 시간을 백엔드에 보낸다. 백엔드는 해당 턴의 점수를 계산하고 페르소나를 갱신한 뒤 행동 패킷을 Unity로 전송하며, 대사는 TTS 워커로 보내 음성 스트림으로 합성한다.

정상적인 한 턴에서 모듈 사이에 전달되는 데이터와 처리 순서는 그림 4.3와 같다. 부분 전사는 발화 중 개입 판정에 사용하고, 최종 전사는 답변 채점과 다음 대사 생성에 사용한다. 행동 패킷과 TTS 음성은 병렬로 전달되며, Unity는 두 데이터를 이용해 면접관의 반응과 음성을 재생한다.




그림 4.3: 정상적인 한 턴의 입력·처리·출력 시퀀스

표 4.5: 주요 처리 단계와 입출력 데이터

처리 단계	입력	출력 및 기록
Unity VAD	마이크 PCM, 음량, 발화 상태	오디오 청크, 발화 시작·종료, VAD 지연·침묵 시간
STT 워커	오디오 청크, 발화 ID	부분 전사, 최종 전사, STT 처리 시간
AI 백엔드	최종 전사, 대화 기록, 시각 피쳐 값	점수, 다음 대사, 페르소나, 행동 패킷
TTS 워커	생성된 대사, 화자 음성	44.1 kHz 음성 청크
Unity Speaker	음성 청크, 행동 패킷	자막·표정·음성 재생, 재생 완료 이벤트

4.5 멀티모달 분석 및 피드백

4.5.1 음성 분석

음성 분석은 Unity와 STT 워커에서 추출한 턴별 피쳐 값을 백엔드가 평가하는 방식이다. VAD는 평균 음량, 음량 변동성, 낮은 음량 구간의 비율, 실제 발화 시간, 의미 있는 침묵 횟수와 반응 시간을 기록한다. STT 워커는 최종 전사와 처리 시간을 기록하며, 백엔드는 전사 문자 수를 실제 발화 시간으로 나누어 발화 속도를 계산한다. 답변 품질과 추임새·내용 밀도는 전체 대화 문맥을 전달받은 LLM의 평가 결과를 사용한다.

음성 피쳐의 기본 계산식과 기준값은 다음과 같다. r 은 평균 음량, σ^2 는 음량 분산, ρ_{low} 는 낮은 음량 구간의 비율, c 는 초당 문자 수, p 는 의미 있는 침묵 횟수이다. $\text{clip}(x, 0, 10)$ 은 점수를 0 ~ 10 범위로 제한하는 함수이다.

$$c = \frac{N_{\text{text}}}{t_{\text{speech}}},$$

$$S_{\text{volume}} = \text{clip} \left(10 - \left\lfloor \frac{|r - 0.1|}{0.05} \right\rfloor - \mathbf{1}[\sigma^2 > 0.05] - \mathbf{1}[\rho_{\text{low}} > 0.3], 0, 10 \right),$$

$$S_{\text{speed}} = \text{clip} \left(10 - \left\lfloor \frac{|c - 5.0|}{1.0} \right\rfloor - \max(0, p - 1), 0, 10 \right).$$

답변 길이 점수와 반응 시간 점수는 다음과 같이 계산한다. t 는 순수 발화 시간, r_t 는 질문 종료 후 답변 시작까지의 시간이며, μ_t 는 단계별 목표 반응 시간이다.

$$S_{\text{length}}(t) = \begin{cases} \lfloor 10t/40 \rfloor, & t < 40, \\ 10, & 40 \leq t \leq 90, \\ 10 - \lfloor (t - 90)/10 \rfloor, & t > 90. \end{cases}$$

$$S_{\text{response}}(r_t) = \text{clip} \left(10 - \left\lfloor \frac{|r_t - \mu_t|}{1.5} \right\rfloor, 0, 10 \right).$$

여기서 $\mu_t = 1.5\text{s}$ 는 자기소개 단계, $\mu_t = 3.5\text{s}$ 는 그 밖의 면접 단계에 적용한다. 최종 음성 피쳐 점수는 유효한 턴별 점수의 평균으로 계산한다.

4.5.2 웹캠 기반 행동 분석

웹캠 분석은 Unity와 분리된 별도 워커가 카메라를 직접 열어 로컬에서 처리하는 구조이다. 따라서 영상 프레임 자체는 네트워크로 전송하지 않고, Unity는 워커에 캘리브레이션 시작·종료와 턴 시작·종료를 WebSocket 텍스트 메시지로 전달한다. 워커는 약 10 fps로 프레임 분석하고, 한 턴이 끝나면 집계된 피쳐 값만 백엔드의 `/vision` 엔드포인트로 전송한다.

표 4.6: 음성 피쳐와 산출 기준

피쳐	추출 · 평가 주체	산출 기준
음량	Unity VAD, 백엔드	평균 음량 0.1, 허용 오차 0.05; 변동성 0.05, 낮은 음량 비율 0.3 초과 시 감점
발화 속도	STT 전사, 백엔드	전사 문자 수/발화 시간; 기준 초당 5.0자
답변 길이	Unity VAD, 백엔드	40초 미만 비례 점수, 40 ~ 90 만점, 90초 초과 감점
반응 시간	Unity 상태, 백엔드	자기소개 1.5초, 그 외 3.5초를 목표치로 차이에 따라 감점
추임새 · 내용 밀도	LLM	전체 대화 기록을 바탕으로 JSON 평가값 생성
답변 품질	LLM	단계 지시와 답변 문맥을 바탕으로 0 ~ 100점 평가

웹캠 분석 위커는 GPU나 Docker를 사용하지 않고 CPU에서 동작하며, 카메라 해상도는 기본적으로 640×480으로 설정한다.

웹캠 분석의 기본 실행 조건은 다음과 같다.

$$f_{\text{vision}} = 10 \text{ fps}, \quad (W, H) = (640, 480), \quad t_{\text{calibration}} \simeq 3 \text{ s}.$$

프레임 분석에는 MediaPipe Tasks API[8]의 Face Landmarker와 Pose Landmarker를 사용한다. Face Landmarker는 얼굴 랜드마크와 얼굴 표면 정보를 추정하는 방식에 기반하며[6], 한 명의 얼굴에 대해 얼굴 변환 행렬과 52개 블렌드셰이프를 출력한다. Pose Landmarker는 실시간 신체 자세 추정을 위해 33개 신체 랜드마크를 출력하는 BlazePose 계열의 구조를 사용한다[2]. 얼굴 변환 행렬에서는 머리의 pitch, yaw, roll을 계산하며, 블렌드셰이프에서는 눈의 상하·좌우 이탈, 눈 깜빡임, 미소, 찡그림 및 표정 변화량 계산에 필요한 값을 추출한다. Pose Landmarker에서는 양쪽 어깨, 양쪽 손목, 코의 정규화 좌표를 사용하여 어깨 기울기, 상체 위치, 손 사용 여부와 얼굴 접촉 여부를 계산한다.

면접 시작 시 약 3초 동안 정면을 바라보는 상태를 캘리브레이션한다. 이 구간에서 얼굴의 평균 yaw와 pitch, 신체 중심의 평균 위치, 어깨 너비를 기준값으로 저장한다. 시선은 별도의 시선 추정 모델을 사용하는 것이 아니라, 캘리브레이션 기준에 대한 머리 방향 변화와 눈 블렌드셰이프를 함께 이용하여 판정한다. 기준 yaw에서 좌우 15도, 기준 pitch에서 상하 12도 이내이고 눈의 좌우·상하 이탈값이 각각 0.35 이하인 프레임을 정면 응시 프레임으로 계산한다. 턴 전체에서 이 조건을 만족한 얼굴 프레임의 비율을 gazeOnTargetRatio로 기록하고, 머리 yaw와 pitch의 표준편차도 함께 기록한다.

시선 점수는 정면 응시 비율과 머리 흔들림을 함께 사용하여 계산한다. r_g 는 정면 응시 프레임의 비율이고, j_g 는 머리 yaw와 pitch 표준편차의 유클리드 크기이다.

$$r_g = \frac{N_{\text{target}}}{N_{\text{face}}}, \quad j_g = \sqrt{\sigma_{\text{yaw}}^2 + \sigma_{\text{pitch}}^2},$$

$$S_{\text{gaze}} = \text{clip} \left(10 \frac{r_g - 0.30}{0.80 - 0.30} - \left\lfloor \frac{\max(0, j_g - 5.0)}{2.5} \right\rfloor, 0, 10 \right).$$

정면 응시 비율이 0.30 이하이면 0점, 0.80 이상이면 10점으로 처리하며, 그 사이는 선형 보간한다. 정면 응시 판정에는 기준 yaw에서 좌우 15° , 기준 pitch에서 상하 12° , 눈 이탈값 0.35 이하의 조건을 사용한다.

자세는 검출된 어깨선의 평균 기울기와 어깨 너비로 정규화한 상체 중심의 흔들림을 이용한다. 손 사용은 손목이 화면 안에 있고 어깨선에서 지나치게 아래로 내려가지 않은 프레임의 비율로 계산한다. 손목 좌표의 공간적 확산은 손 동작 범위로 기록하며, 손목이 코 주변에 어깨 너비의 일정 비율 이내로 약 1초 이상 머무르면 얼굴 접촉 횟수로 기록한다. 표정은 선택한 14개 블렌드셰이프 축의 표준편차 평균을 표정 변화량으로 사용하고, 미소와 찡그림이 나타난 프레임의 비율도 산출한다. 눈 깜빡임과 손목 이동 에너지는 로그에는 기록하지만, 현재 최종 점수에는 사용하지 않는다.

자세와 손 사용 점수는 검출된 어깨 기울기 τ , 상체 흔들림 σ_b , 손 사용 비율 u , 손 동작 범위 e , 얼굴 접촉 횟수 F 를 이용하여 계산한다.

$$S_{\text{posture}} = \text{clip} \left(10 - \left\lfloor \frac{\max(0, \tau - 8.0)}{3.0} \right\rfloor - \left\lfloor \frac{\max(0, \sigma_b - 0.030)}{0.020} \right\rfloor, 0, 10 \right),$$

$$S_{\text{usage}}(u) = \begin{cases} 2, & u \leq 0.02, \\ 10 - \lfloor (0.15 - u)/0.05 \rfloor, & 0.02 < u < 0.15, \\ 10, & 0.15 \leq u \leq 0.75, \\ 10 - \lfloor (u - 0.75)/0.15 \rfloor, & u > 0.75, \end{cases}$$

$$S_{\text{gesture}} = \text{clip} (S_{\text{usage}}(u) - \mathbf{1}[u \geq 0.15 \wedge e < 0.15] - \max(0, F - 1), 0, 10).$$

표정 점수는 표정 변화량 v_e , 찡그림 비율 r_f , 미소 비율 r_s 를 사용한다. 눈 깜빡임 점수는 현재 설정에서 비활성화되어 있다.

$$S_{\text{expression}} = \text{clip} \left(10 - 21[v_e < 0.012] - \left\lfloor \frac{\max(0, r_f - 0.15)}{0.15} \right\rfloor + \mathbf{1}[r_s \geq 0.15], 0, 10 \right).$$

턴 종료 시 워커는 프레임 수, 얼굴·자세 검출률, 시선, 자세, 손 사용, 표정과 관련된 원시 피쳐 값을 턴 단위로 집계한다. 정상 답변과 재답변은 최소 5개 프레임이 확보된 경우 채점 대상으로 사용하고, 짧은 개입 직후 반응 구간은 최소 프레임 조건을 낮춰 별도로 기록한다. 얼굴 검출률이 0.5 미만인 턴은 시각 점수 계산에서 제외하며, 자세 검출률이 0.5 미만이면 자세와 손 사용 항목을 감점하지 않고 측정 불가에 해당하는 중립값으로 처리한다. 백엔드는 유효한 정상 답변과 재답변을 대상으로 턴별 점수를 계산한 뒤 평균을 내어 시선, 자세, 제스처, 표정의 네 가지 최종 점수를 산출한다. 개입으로 잘린 구간과 개입 직후 반응 구간은 중복 집계를 막기 위해 로그에는 남기되 최종 시각 점수에는 포함하지 않는다.

시각 피쳐의 채점 가능 여부는 다음 조건으로 결정한다.

$$\frac{N_{\text{face}}}{N_{\text{frame}}} \geq 0.5, \quad \frac{N_{\text{pose}}}{N_{\text{frame}}} \geq 0.5, \quad N_{\text{frame}} \geq 5.$$

얼굴 검출률이 0.5 미만이면 해당 턴을 시각 점수에서 제외하고, 자세 검출률이 0.5 미만이면 자세와 손 사용 점수를 중립값 5점으로 처리한다. 개입 직후 반응 구간은 최소 3개 프레임을 기준으로 별도 기록하며 최종 점수에는 포함하지 않는다.

개입이 발생하면 답변 구간을 TRUNCATED, REACTION, REANSWER로 구분해 개입 전후의 행동을 별도로 분석하고 중복 집계를 방지한다.

개인정보 처리 측면에서 웹캠 원본 프레임은 비전 워커에서 로컬로 분석하고, 백엔드에는 턴 단위로 집계된 피쳐 값만 전달한다. 음성도 로컬 STT·TTS 워커를 통해 처리하며, 원시 음성·영상은 세션 JSON 로그에 저장하지 않는다. 다만 질문 생성과 답변 평가를 위해 전사 텍스트, 자기소개 및 이력서 관련 정보가 OpenAI 또는 Groq API로 전송될 수 있다. OpenAI API는 입력·출력을 모델 학습에 사용하지 않는 기본 정책을 제공하며, Groq API는 추론 요청의 입력·출력을 기본적으로 보관하지 않는 정책을 제공하지만, 두 서비스 모두 운영·악용 탐지 목적의 임시 로그가 생성될 수 있다[10, 4]. 또한 로컬 진단 프레임과 분석 피쳐 CSV도 별도로 저장될 수 있다. 따라서 원시 미디어의 외부 전송과 세션 로그 저장은 줄였으나, 보존 기간·삭제·접근 통제에 관한 요구사항은 부분적으로만 충족한 것으로 판단한다.

4.5.3 개입 판정과 처리

개입은 조건 C에서만 활성화되며, 기술 질문과 꼬리질문 단계에서 사용한다. 개입은 주제 이탈형과 길이·침묵형으로 나누어 처리한다. 주제 이탈형은 현재 질문에 대한 재답변을 유도하고, 길이·침묵형은 현재 답변을 종료한 뒤 다음 질문으로 진행한다. 개입에 사용하는 주요 임계값은 다음과 같다.

$$\begin{aligned}
N_{\max} &= 3, & T_{\text{cooldown}} &= 8 \text{ s}, \\
T_{\text{long}} &= 90 \text{ s}, & T_{\text{silence}} &= 20 \text{ s}, \\
T_{\text{grace}} &= 8 \text{ s}, & N_{\text{partial}} &= 25.
\end{aligned}$$

여기서 $N_{\max}$ 는 세션당 최대 개입 횟수, T_{cooldown} 은 개입 사이의 유예 시간, T_{long} 은 긴 답변의 기준, T_{silence} 는 긴 침묵의 기준이다. T_{grace} 가 지나고 공백을 제외한 부분 전사 문자가 N_{partial} 이상 누적된 경우에만 주제 이탈 판정을 수행한다.

긴 답변과 긴 침묵은 Unity의 로컬 신호가 직접 개입 요청을 보내고, 주제 이탈은 부분 전사와 현재 질문을 백엔드에 전달하여 확인한다. STT 워커의 체크포인트 확인 주기는 다음과 같이 설정하였다.

$$\Delta t_{\text{checkpoint}} \simeq 0.5 \text{ s}$$

STT 워커는 이 주기로 최근 오디오 구간을 확인하고, 문장 종결로 판단되는 체크포인트가 생성되면 누적 부분 전사를 백엔드로 전달한다. 백엔드는 원시 오디오 청크마다 판정하지 않고, 체크포인트 전사가 도착할 때마다 주제 이탈 여부를 확인한다. 이때 LLM은 질문과 답변의 관련성을 불리언 값으로 판정하며, 사례 도입처럼 질문과 연결될 가능성이 있거나 판단이 애매한 경우에는 이탈로 처리하지 않는다. 개입이 확정되면 현재 답변은 TRUNCATED로 기록하고 개입 대사를 재생한다. 주제 이탈의 경우 같은 질문에 대한 재답변을 유도하며, 잘린 답변과 재답변의 단계 점수는 각각 0.5의 가중치로 결합한다. 개입 직후의 반응 구간은 일반 답변과 구분하여 기록하고, 이후의 정상 답변 또는 재답변만 최종 피쳐 집계에 사용한다.

주제 이탈형 개입이 발생한 경우의 세부 처리 순서는 그림 4.4와 같다. 부분 전사가 체크포인트로 전달된 뒤 백엔드가 LLM에 관련성 판정을 요청하며, 개입이 확정되면 기존 답변과 늦게 도착한 전사 결과를 다음 면접 단계에 반영하지 않는다.

4.5.4 통합 점수 및 피드백 생성

면접 종료 시 음성 6개와 영상 4개 항목을 각각 0 ~ 10점으로 계산한다. 음성 항목은 음량, 속도, 답변 길이, 추임새, 답변 품질, 반응 시간이고 영상 항목은 시선, 자세, 제스처, 표정이다. 각 항목의 최종 점수는 유효한 턴별 점수의 평균으로 계산한다.

웹캠 피쳐가 제공되는 경우 종합점수와 웹캠 미사용 시의 환산식은 다음과 같다. v_j 는 영상 4개 항목, a_i 는 음성 6개 항목의 점수이다.

$$S_{\text{voice}} = \sum_{i=1}^6 a_i, \quad S_{\text{vision}} = \sum_{j=1}^4 v_j,$$




그림 4.4: 주제 이탈형 개입이 발생한 톤의 처리 시퀀스

$$S_{\text{overall}} = \begin{cases} S_{\text{voice}} + S_{\text{vision}}, & \text{웹캠 피처가 유효한 경우,} \\ \frac{100}{60} S_{\text{voice}}, & \text{웹캠 피처가 없는 경우.} \end{cases}$$

LLM이 단계별 답변에 대해 산출하는 점수와 최종 답변 품질 점수의 관계는 다음과 같다. q_k 는 k 번째 채점 대상 답변의 LLM 점수이고, n 은 유효한 답변 수이다.

$$S_{\text{quality}} = \text{round} \left(\frac{1}{10n} \sum_{k=1}^n q_k \right), \quad 0 \leq q_k \leq 100.$$

답변 길이 최종 점수는 발화 시간 점수와 LLM이 산출한 내용 밀도 점수의 평균으로 계산한다. S_{time} 은 4.5.1의 발화 시간 점수이고, S_{density} 는 LLM의 내용 밀도 점수이다.

$$S_{\text{answer length}} = \left\lfloor \frac{S_{\text{time}} + S_{\text{density}}}{2} \right\rfloor.$$

추임새 점수와 내용 밀도 점수는 전체 대화 기록을 LLM에 전달하여 각각 0 ~ 10점으로 생성한다. 최종 결과에는 종합점수, 단계별 점수, 각 피처별 점수, 강점·개선점, 총평, 평균 발화 시간과 의미 있는 침묵 횟수를 함께 기록한다.

제5장 구현 결과 및 시연

5.1 최종 면접 진행 과정

최종 면접은 다음 순서로 진행된다.

1. 설정 화면에서 회사, 직무 및 이력서 정보를 입력한다.
2. 백엔드가 세션을 생성하고 첫 질문을 준비한다.
3. 면접관이 자기소개를 요청하고 사용자의 답변을 STT로 변환한다.
4. 백엔드가 답변을 분석하여 기술 질문과 꼬리질문을 순차적으로 생성한다.
5. 답변 점수에 따라 다음 면접관의 페르소나와 표정이 결정된다.
6. 개입 기능이 활성화된 경우 대상 단계와 페르소나 조건을 만족할 때 주제 이탈, 긴 답변 또는 긴 침묵에 대해 개입한다.
7. 마무리 발화가 끝나면 음성·영상 피쳐 값과 대화 기록을 이용하여 최종 피드백을 생성한다.

Unity 클라이언트에서는 3차원 면접 공간과 가상 면접관을 표시하고, 면접관의 질문과 자막을 함께 제공한다. 실제 실행 화면은 그림 5.1과 같다.

5.2 동적 페르소나 및 면접관 반응

동적 페르소나는 백엔드가 답변 점수를 바탕으로 결정하고, Unity는 전달받은 감정값을 면접관 Animator와 표정 프리셋에 적용한다. 높은 점수의 답변 뒤에는 긍정 또는 경청 표정이 사용되고, 중간 점수에서는 중립적인 경청 반응이 사용된다. 낮은 점수가 반복되면 부정 페르소나가 유지되며, 개입 게이트를 통과하면 면접관이 대화 흐름을 조정한다.



그림 5.1: Unity 기반 가상 면접 진행 화면

개입은 표정·상태를 바꾸는 컷인 메시지와 실제 대사를 분리하여, LLM 대사 생성보다 먼저 면접관이 반응하도록 한다. 주제 이탈형은 부분 전사를 백엔드의 LLM에 전달해 질문과의 관련성을 판정하고, 이탈 시 현재 질문의 재답변을 유도한다. 긴 답변·긴 침묵형은 답변을 종료하고 다음 단계로 진행한다.

5.3 음성·영상 기반 피드백

현재 구현된 결과 화면은 음성 6개 항목과 영상 4개 항목을 분리하여 표시할 수 있도록 구성하였다. 음성 항목은 답변의 내용 품질뿐 아니라 말하는 방식과 반응 시간을 함께 평가하며, 영상 항목은 웹캠 분석이 유효한 턴에 대해서만 계산한다. 얼굴이 충분히 검출되지 않은 세션에서는 시각 항목을 억지로 감점하지 않고 음성 중심 결과로 전환한다.

시스템의 피드백 기능은 질문 생성과 음성 재생 지연, 답변별 점수, 음성·영상 피쳐 값, 개입 처리 이력을 종합하여 사용자가 자신의 면접 수행 결과를 확인할 수 있도록 한다. 정량 지표는 턴별 로그와 세션 기록을 기반으로 계산하며, 웹캠 분석이 불가능한 경우에는 음성 중심 결과로 전환한다.

그림 5.2는 면접 종료 후 음성·영상 분석 결과를 항목별 점수와 종합 피드백으로 표시하는 결과 화면이다.

면접 결과				
1. 시선 처리		6/10	6. 답변 목소리 빠르기	4/10
2. 손 사용		8/10	7. 답변 길이	5/10
3. 자세 안정성		9/10	8. 답변 내 팔러 닫어 여부	7/10
4. 표정 변화		10/10	9. 답변의 정확도	2/10
5. 답변 목소리 크기		9/10	10. 답변 반응 속도	9/10
총점: 69/100		전체적으로 지원자는 기술적 경험이 풍부하지만, 질문에 대한 구체적인 답변을 준비하는 것이 필요합니다. 개선된 커뮤니케이션 능력을 통해 더 나은 인상을 줄 수 있을 것입니다.		처음 화면으로 이동

그림 5.2: 음성·영상 분석을 이용한 최종 면접 결과 화면

5.4 시스템 실행 방법

본 절에서는 실제 실행 환경을 준비하고 각 구성 요소를 기동하는 방법을 설명한다. 실행 대상은 Docker 기반 STT 워커 컨테이너, TTS 워커 컨테이너, Webcam 분석 워커, Python 기반 AI 백엔드, Unity 클라이언트이다. STT와 TTS 워커는 각각 별도의 컨테이너에서 실행하여 CUDA 및 모델 라이브러리 환경을 분리하고, Webcam 분석 워커와 AI 백엔드는 호스트의 Python 가상환경에서 실행한다.

5.4.1 실행 하드웨어와 모델 설정

측정 및 최종 실행은 NVIDIA GeForce RTX 4060 Ti 8 GB GPU, Intel Core i5-12400F CPU, 16 GB RAM이 장착된 PC에서 수행하였다. STT와 TTS 워커는 GPU를 사용하고, 웹캠 분석 워커는 CPU에서 실행하였다. 운영체제와 컨테이너 실행 환경은 Docker Desktop과 WSL2를 기준으로 하였다.

STT 워커에는 로컬에 저장한 Faster-Whisper의 Whisper large-v3-turbo 모델을 사용하였다. 모델 파일은 CTranslate2 형식이며 현재 실행 폴더 기준 약 1.62 GB이다. 모델은 `device=cuda`, `compute_type=float16`, `local_files_only=true`로 초기화하였다. 최종 전사에서는 한국어로 지정하고 `beam_size=5`, VAD 필터, 이전 문맥 조건, 단어 단위 타임스탬프를 사용하였다. 문장 종결 후보와 체크포인트를 확인하는 부분 전사는 지연을 줄이기 위해 `beam_size=2`, 이전 문맥 조건 해제, VAD 필터 사용, 단어 단위 타임스탬프

해제 설정으로 실행하였다.

TTS 워커에는 Fish Speech 1.5를 사용하였다. 모델 폴더에는 Text2Semantic 모델과 Firefly VQGAN 가중치가 포함되며 현재 실행 폴더 기준 저장 용량은 약 3.34 GB이다. CUDA 사용 시 GPU의 BF16 지원 여부에 따라 BF16 또는 FP16을 사용하고, CPU 실행 시에는 FP32를 사용하도록 구성하였다. Text2Semantic 모델의 KV 캐시는 배치 크기 1, 최대 시퀀스 길이 8192로 초기화하고, `torch.compile`의 Inductor 백엔드를 적용하였다. 스트리밍 합성은 최대 1024개 토큰, temperature 0.5, top-p 0.7로 실행하며, 생성 토큰 50개 단위로 오디오 청크를 디코딩하여 Unity로 전송한다.

5.4.2 환경 및 모델 준비

Docker Desktop과 WSL2, NVIDIA Container Toolkit, Python 3.10 이상, Unity 실행 환경을 준비한다. STT 워커에는 Whisper 모델 파일을, TTS 워커에는 Fish Speech 1.5 모델 파일을 배치한다. TTS 워커의 경우 워커 폴더에 레퍼런스 음성 파일 `speaker.mp3`를 두며, 모델 경로는 `tts-worker-docker/model/fish-speech-1.5`로 구성한다. 두 워커의 Dockerfile과 Dev Container 설정은 각각 `verbal_process/stt-worker-docker`와 `verbal_process/tts-worker-docker`에 있다.

5.4.3 환경 변수 설정

먼저 백엔드 폴더의 `.env` 파일을 생성한다. 다음 설정은 백엔드가 호스트에서 실행되고, TTS 워커가 호스트의 8001번 포트에 연결되는 로컬 실행 기준이다.

```
1 LLM_PROVIDER=openai
2 OPENAI_API_KEY=your_openai_api_key
3 OPENAI_MODEL=gpt-4o-mini
4 TTS_WORKER_URL=http://127.0.0.1:8001/process
5 TTS_WS_URL=ws://127.0.0.1:8001/ws/tts
6 HOST=0.0.0.0
7 PORT=8080
8 PROXY_AUDIO_TO_STT=false
9 SKIP_TTS=false
```

다음으로 `stt-worker-docker/.env`를 생성한다. 컨테이너 안의 STT 워커가 호스트에서 실행 중인 백엔드의 `/ws/tts`에 접속할 수 있도록 `host.docker.internal`을 사용한다.

```
1 TTS_WORKER_WS_URL=ws://host.docker.internal:8080/ws/tts
```

```
2 CHECKPOINT_ENABLED=true
3 CHECKPOINT_BACKEND_ENABLED=true
```

TTS 워커는 `tts-worker-docker/.env`에서 레퍼런스 음성에 대응하는 문장을 설정한다. 별도의 설정이 없으면 코드에 정의된 기본 문장을 사용한다.

```
1 REFERENCE_DIALOGUE=reference_sentence_for_speaker_audio
```

다른 컴퓨터에서 실행하는 경우에는 연결 주소를 해당 컴퓨터의 IP로 변경하고, 필요한 포트(8000, 8001, 8002, 8080)의 방화벽과 Docker 포트 바인딩을 설정한다.

5.4.4 Docker 워커 실행

`verbal_process` 폴더에서 `open_container.ps1`을 실행하거나 두 워커 폴더를 각 Visual Studio Code로 연다. 각 폴더에서 명령 팔레트의 `Dev Containers: Reopen in Container`를 실행하면 `Dockerfile`을 바탕으로 컨테이너가 빌드되고 시작된다. STT와 TTS의 Dev Container 설정에는 GPU 사용 옵션과 각각 8000번, 8001번 포트가 지정되어 있다.

컨테이너가 준비되면 각 컨테이너의 터미널에서 워커를 실행한다. 먼저 TTS 워커를 실행하여 Fish Speech 모델을 초기화한 뒤, STT 워커를 실행한다.

```
1 # tts-worker-docker container
2 python tts-worker.py
3
4 # stt-worker-docker container
5 python stt-worker.py
```

TTS 워커는 8001번 포트, STT 워커는 8000번 포트에서 실행된다. TTS 워커는 시작 과정에서 모델 로딩과 워업을 수행하므로 초기화 완료 메시지가 출력된 뒤 다음 단계를 진행한다.

5.4.5 Webcam 분석 워커 실행

Webcam 분석 워커는 MediaPipe 기반의 영상 분석을 수행하며, Docker 워커와 별도의 Python 프로세스로 실행한다. `vision_process` 디렉터리에서 다음 명령을 실행한다.

```
1 uvicorn server:app --host 0.0.0.0 --port 8002
```

Webcam 분석 워커는 8002번 포트에서 실행되며, Unity와는 `ws://127.0.0.1:8002/ws/vision`으로 연결한다. 실행 후 `http://127.0.0.1:8002/health`에 접속하여 워커와 카메라 상태를 확인한다.

5.4.6 Python 백엔드 실행

백엔드 폴더에서 Python 가상환경을 활성화하고 의존성을 설치한다. 이후 app 패키지를 기준으로 Uvicorn을 실행한다.

```
1 cd VRoom_Backend
2 python -m venv .venv
3 .venv\\Scripts\\activate
4 pip install -r requirements.txt
5 python -m uvicorn app.main:app --host 0.0.0.0 --port 8080
```

백엔드는 8080번 포트에서 실행되며, .env의 OPENAI_API_KEY를 사용하여 LLM API를 호출한다. 실행 후 <http://127.0.0.1:8080/health>에 접속하여 서버 상태를 확인할 수 있다.

5.4.7 Unity 클라이언트 연결

STT 워커, TTS 워커, Webcam 분석 워커, 백엔드가 모두 실행된 상태에서 Unity 프로젝트를 열고 클라이언트를 실행한다. Unity는 백엔드의 /ws/control에 연결하고, STT 워커에는 음성 스트림을, Webcam 분석 워커에는 영상 스트림을 전달한다. 백엔드는 STT 워커에서 받은 전사 결과와 Webcam 분석 결과를 처리한 뒤 TTS 워커에 합성할 대사를 전달하며, 합성된 음성은 Unity에서 재생된다. 각 서비스의 주소가 기본 포트와 다르다면 Unity의 백엔드, STT 및 Webcam 연결 설정도 동일한 주소로 변경해야 한다.

5.5 음성 처리 지연 측정 결과

음성 처리 파이프라인의 응답 시간을 확인하기 위해 프로젝트 참여자 3명 중 1명이 부록 A의 전체 응답 대본을 사용하여 4개 세션을 수행하였다. 각 세션은 자기소개, 기술 질문, 두 번의 꼬리 질문, 인성 질문, 마무리 순서로 진행하였다. 총 24개 사용자 답변 중 개입이 발생하지 않은 턴의 답변 22개를 집계하였으며, 개입으로 중단된 2개 턴은 지연 통계에서 제외하였다. VAD 종료 판단 지연은 마지막 음성 프레임 이후 발화 종료로 판단할 때까지의 시간이며, STT 처리 지연은 STT 워커가 발화 종료 신호를 받고 최종 전사를 완료할 때까지의 시간이다. 선행 연구에서는 인간 대화의 턴 교체 공백이 대표적으로 약 200ms 수준으로 나타나며, 상대 발화를 듣고 응답을 준비하는 데 필요한 시간은 약 600 ~ 1500ms로 추정된다. 이 값들은 인간 대화와 인지 처리 시간에 대한 연구 결과이지 음성 인식·LLM·음성 합성을 포함한 시스템의 보편적인 응답 시간 표준은 아니다. 본 과제에서는 이를 참고하여 사용자의

마지막 음성 프레임부터 Unity에서 첫 음성 청크를 재생하기까지의 시간을 대화 응답 지연으로 정의하고, 최대 2s 이내를 최종 평가 기준으로 설정하였다[12]. TTS 첫 청크 생성 시간은 TTS 요청부터 첫 음성 청크가 백엔드에 도착할 때까지의 시간으로 계산하였다. Unity 재생 시작까지의 시간은 VAD가 발화 종료를 판단한 시점부터 Unity에서 첫 음성 재생이 시작될 때까지의 시간이다. 측정 결과는 표 5.1과 같다.

표 5.1: 개입이 발생하지 않은 턴의 음성 처리 지연 측정 결과

측정 항목	평균 (초)	중앙값 (초)
STT 처리 지연	1.68	1.01
LLM 응답 완료	1.77	1.67
TTS 첫 청크 생성	2.34	2.30
VAD 종료 판단 지연	1.65	1.03
VAD 종료 판단 → Unity 재생 시작	5.99	6.00
마지막 음성 프레임 → Unity 재생 시작	7.64	7.63

측정 결과 마지막 음성 프레임부터 Unity 재생 시작까지의 평균 지연은 7.64s로 나타나, 설정한 2s 기준을 충족하지 못하였다. 이는 현재 STT, LLM, TTS가 순차적으로 처리되는 구조와 VAD 종료 판단 지연이 함께 반영된 결과이다.

원시 로그에는 턴별 VAD 종료 판단 지연, STT 처리 지연, LLM 시작·종료 시각, TTS 요청·첫 청크 시각, Unity 재생 시작 시각이 기록된다. 다만 VAD와 STT의 시작 시각이 독립 이벤트로 남아 있지 않으므로, 전체 구간을 하나의 간트로 재구성하기보다는 단계별 평균과 중앙값을 비교하는 방식으로 시각화하였다. 그림 5.3은 표의 측정값을 단계별로 비교한 결과이다.

VAD 종료 판단 지연의 평균이 중앙값보다 큰 것은 문장이 끝난 것이 정상적으로 감지된 일부 턴에서는 약 1초의 침묵 임계값이 사용되었고, 그렇지 않은 턴에서는 기본값인 약 3초의 침묵 임계값이 사용되었기 때문이다. VAD 종료 판단 이후 Unity 재생 시작까지의 시간에는 STT 처리, LLM 응답, TTS 첫 청크 생성, 음성 데이터 전달 및 Unity 버퍼링 시간이 포함된다. 마지막 음성 프레임 이후 Unity 재생 시작까지의 값은 VAD 종료 판단 지연과 VAD 종료 판단 이후의 처리 시간을 턴별로 합산한 값이다.

5.6 STT 전사 성능 참고 측정

부록 A의 전체 응답 대본과 실제 발화의 전사 결과를 비교하여 음성 인식 성능을 참고 측정하였다. 프로젝트 참여자 3명 중 1명이 같은 대본으로 수행한 4개 세션 중, 대본에 제시된 예상 질문과 실제 질문의 흐름이 일치하고 발화 도중 예상하지 못한 잡음이 포함되지 않은 19개 턴을 대상으로 공백과 구두점을 제외한 문자 단위 편집거리를 계산하였다. 그 결과




그림 5.3: 개입이 발생하지 않은 턴의 단계별 음성 처리 지연 비교

참고 문자 오류율(CER)은 약 5.86%로 나타났다. 예상 질문이 대본과 다르게 제시되었거나 발화 도중 예상하지 못한 잡음이 들어간 턴은 대본과 실제 발화의 비교 기준이 달라 계산에서 제외하였다. 이 값은 실제 발화의 수기 전사본이 아닌 사전 작성 대본을 기준으로 산출한 참고값이므로, STT 모델의 절대적인 정확도로 해석하지 않는다. Whisper의 공개 한국어 기준값인 5.2%와 비교하면 유사한 수준으로 볼 수 있으나, 데이터셋과 측정 조건이 다르므로 직접 비교에는 한계가 있다[11].

제6장 성능 평가 및 실험 분석

5장에서는 구현 결과와 1인 4세션 기준의 참고 측정을 제시하였다. 본 장에서는 2026년 9월 4일에 참가자 3명이 3개 조건으로 수행한 대면 실험의 로그를 이용하여, 구성 요소별 성능과 평가 체계의 타당성을 정량적으로 분석한다. 모든 수치는 세션 JSON 16건, 백엔드·STT·TTS·영상 워커 로그, Unity Editor 로그, 영상 피쳐 CSV, 결과 화면 캡처 9장을 재분석하여 산출하였으며, 추정하거나 외부에서 인용한 값은 사용하지 않았다.

6.1 평가 개요와 실험 설계

6.1.1 평가 목적과 평가 기준

본 평가의 목적은 두 가지이다. 첫째는 VRoom을 구성하는 각 처리 요소, 즉 음성 활동 감지, 음성 인식, LLM 기반 채점, 음성 합성, 영상 분석이 어느 정도의 성능으로 동작하는지를 개별적으로 측정하는 것이다. 둘째는 이들 요소가 결합되어 산출되는 최종 결과물, 즉 10개 항목 점수와 면접관 개입 판정이 실제 면접 수행을 타당하게 반영하는지를 검토하는 것이다.

5장 5.5절에서는 종단 응답 지연의 최종 평가 기준을 2s 이내로 설정하였다[12]. 본 장에서는 달성 실패의 정도를 구분하기 위해 이 기준을 3단계로 확장하여 사용한다. 대화형 인터페이스의 응답 시간에 대한 고전적 지침은 약 1s를 사고의 흐름이 유지되는 한계로, 약 10s를 사용자의 주의가 이탈하는 한계로 제시한다[9]. 이를 참고하여 목표 수준은 중앙값 2.0s 이하, 허용 수준은 95 백분위수 4.0s 이하, 실패 수준은 10s 초과 턴 비율 0%로 정의한다. 목표 수준은 5.5절에서 설정한 값이고, 실패 수준은 사용자 주의가 이탈하는 응답 시간 한계[9]에서 가져왔으며, 허용 수준은 선행 연구에서 직접 제시된 값이 아니라 목표값의 두 배를 운영 기준으로 설정한 것이다.

그 밖의 비기능 요구사항도 검증 가능한 형태로 기준을 정한다. 발화 종료 판정 지연 1.5s 이하, 문자 오류율 10% 이하, 전문 용어 인식률 90% 이상, 세션 완주율 90% 이상이다.

6.1.2 실험 설계

본 실험은 면접관의 반응 방식을 세 가지 조건으로 나누어, 동일한 답변에 대해 시스템이 어떻게 다르게 동작하는지를 관찰하는 피험자 내 설계로 구성하였다. 조건 A는 답변 점수와 무관하게 중립 페르소나를 유지하고 개입하지 않는 기준선 조건이고, 조건 B는 점수에 따라 페르소나가 전환되나 답변 도중 개입하지 않으며, 조건 C는 페르소나가 전환되면서 주제 이탈·긴 답변·긴 침묵에 개입한다.

참가자는 개발 팀원 3명이며 각자 서로 다른 직무의 이력서로 3개 조건을 모두 수행하였다. P1은 Unity 2년차와 Photon 멀티플레이 경험을 담은 넥슨 게임 클라이언트 프로그래머 이력서를, P2는 Kotlin·Spring Boot와 MySQL·Redis·Kafka·Kubernetes 운영 경험을 담은 네이버 백엔드 이력서를, P3는 PyTorch·Hugging Face 기반 자연어처리와 RAG·FAISS 구현 경험을 담은 업스테이지 AI 엔지니어 이력서를 사용하였다. 이력서는 실험 전에 파일로 고정하여 9개 세션 내내 동일한 내용을 사용하였고, 조건 지정은 이력서 파일 상단의 [조건] 항목으로 전달하였다.

조건 제시 순서는 순서 효과를 상쇄하기 위해 라틴 방격으로 계획하였으나, 초기 실행에서 발생한 장애로 조건 C를 다시 수행하면서 실제 순서는 P1이 C-A-B, P2가 B-C-A, P3가 C-B-A가 되었다. 조건 C가 두 참가자에서 첫 번째로, 조건 A가 두 참가자에서 마지막으로 배치되어 순서 효과가 완전히 통제되지 못하였다.

6.1.3 표준화된 답변 프로토콜

조건 간 비교가 성립하려면 세 조건에서 답변 내용이 동일해야 한다. 답변이 조건마다 달라지면 관찰된 차이가 조건의 효과인지 답변의 효과인지 구분할 수 없다. 이를 통제하기 위해 참가자별로 단계마다 내용·길이·품질을 규정한 응답 대본을 사전에 작성하여 세 조건에 공통으로 사용하였다(표 6.1). P2의 대본은 부록 A와 동일하며, P1과 P3의 대본은 부록 C에 수록한다.

이 프로토콜의 중요한 성질은 정답이 사전에 정의된다는 점이다. 각 세션에는 주제 이탈 1건과 90초 초과 답변 1건이 계획적으로 포함되어 있으므로, 시스템이 이를 검출했는지 여부로 개입 판정의 재현율을, 그 밖의 구간에서 개입이 발생했는지 여부로 정밀도를 계산할 수 있다. 또한 자기소개와 인성 질문은 고품질, 기술 질문과 꼬리질문은 저품질로 설계되어 있으므로 채점기가 산출한 점수의 순위가 이 설계와 일치하는지를 검증할 수 있다.

표 6.1: 참가자 응답 프로토콜

면접 단계	답변 성격	목표 길이	의도
자기소개	준비된 고품질 답변	40 ~ 60초	고품질 답변의 인식 확인
기술 질문	의도적 저품질. 구체적 사례·수치·기술명을 모두 배제한 일반론	30 ~ 40초	점수를 낮추어 부정 페르소나로 전환시키는 시발점
꼬리질문 1	의도적 저품질. “직접 담당하지 않아 모른다” 계열	20 ~ 30초	점수의 추가 하락
꼬리질문 2	관련 답변 20 ~ 30초 후 명시적 주제 이탈(날씨·운동·스포츠)	개입 발생 시 까지	주제 이탈형 개입의 정답 이벤트
인성 질문	준비된 고품질 답변을 90초 이상 지속	90초 이상	긴 답변형 개입의 정답 이벤트이자 고품질 답변의 채점 검증
마무리	자유	20 ~ 40초	—

6.1.4 측정 환경

측정 환경은 표 6.2과 같다. 5장의 실행 하드웨어 설명에 더해, 두 대의 호스트를 분리하여 사용한 대면 실험의 구성을 명시한다.

표 6.2: 대면 실험의 실행 구성

구분	내용
호스트 구성	데스크톱(NVIDIA GeForce RTX 5070 Ti, Windows 11 + WSL2, Docker Desktop)에서 Unity 클라이언트, AI 백엔드, STT·TTS 워커 컨테이너를 실행하고, 노트북에서 영상 분석 워커와 웹캠을 실행. 참가자는 노트북 앞에 착석하고 원격 데스크톱으로 Unity 화면을 조작
네트워크	두 호스트를 VPN으로 연결. 마이크 입력은 노트북에서 가상 오디오 케이블을 거쳐 데스크톱 Unity로 전달
음성 모델	STT는 Whisper large-v3-turbo(Faster-Whisper 구현, CUDA, FLOAT16, 포트 8000), TTS는 Fish Speech 1.5(torch.bfloat16, CUDA, 디코드 함수 컴파일, 레퍼런스 화자 1개, 포트 8001)
LLM·영상	OpenAI gpt-4o-mini의 구조화 JSON 응답, MediaPipe Face/Pose Landmarker(입력 640×480, 목표 10 fps, 포트 8002)
백엔드	FastAPI/Uvicorn, 포트 8080

6.1.5 세션 선별과 데이터 규모

당일 16회의 세션 실행이 기록되었고 이 중 9회를 분석 대상으로 확정하였다. 선별 기준은 면접이 DONE 단계까지 정상 종료되어 최종 피드백이 산출되었을 것, 음성·영상 입력 장치가 정상 동작하여 답변 프로토콜이 실제로 수행되었을 것, 참가자와 조건의 조합이 중복되지 않을 것의 세 가지이며 중복 시 최후 실행을 채택하였다. 선별된 9세션의 결과 화면 캡처에 표시된 항목 점수와 총점이 세션 JSON의 값과 모두 일치함을 확인하였다. 전체 실행 목록과

제외 사유는 부록 D에 수록한다.

정상 종료에 도달한 실행은 11회로 세션 완주율은 68.8%이며, 분석 가능한 유효 세션까지 좁히면 세션 수율은 56.3%이다. 이는 완주율 기준 90%에 크게 미치지 못한다. 실패 사유 5건이 모두 Unity와 백엔드 사이 제어 소켓의 비정상 종료라는 점은, 원격 데스크톱과 VPN을 경유하는 실행 구성에서 연결 안정성이 가장 취약한 지점임을 보여준다.

유효 9세션의 총 면접 시간은 2,839.8s(47분 20초)이고 세션당 평균 길이는 315.5s이다. 사용자 답변 턴은 54개이며 이 중 53개에서 음성 피처가 산출되었다. 영상 피처 구간은 개입 세션의 TRUNCATED · REACTION · REANSWER 위상을 포함하여 59개이고, 채점 대상 턴은 36개이다. 개입 게이트 판정 기록은 16회 실행 전체에서 44건이다.

6.1.6 분석 방법

시계열 분석을 위해 서로 다른 프로세스의 로그를 하나의 시간축에 정렬하였다. TTS 워커는 컨테이너 내부에서 협정 세계시로 기록하므로 9시간을 더해 한국 표준시로 변환한 뒤 영상 워커 CSV의 턴 종료 기록 시각과 맞추었다. 정렬의 타당성은 6.2.3절 회귀 분석의 절편이 5.5절의 독립 측정치와 일치하는지로 사후 검증하였다. 통계량은 평균, 중앙값, 표준편차, 백분위수를 함께 제시하며, 표본이 작은 항목에서는 점추정값과 표본 수를 병기하고 해석의 한계를 명시한다.

6.2 응답 지연 성능 평가

6.2.1 측정 구간의 정의

5.5절의 측정은 참가자 1명이 4개 세션을 수행한 결과를 대상으로 하였다. 본 절에서는 참가자 3명이 수행한 유효 9세션을 대상으로 같은 파이프라인을 재측정한다. 분석 대상은 개입으로 중단되지 않은 위상이고, 음성 피처와 영상 피처가 모두 산출되었으며, 후속 면접관 대사의 TTS 합성 요청이 로그에서 식별되는 턴 47개이다. 측정 구간은 다음과 같이 정의한다.

구간 ① 마지막 음성 프레임에서 발화 종료 판정까지. 영상 턴 구간 길이에서 사용자 반응 시간과 발화 시간을 뺀 후행 무음으로 산출한다. 영상 턴은 면접관 발화가 끝나 마이크가 열리는 시점에 시작하여 VAD 종료 판정 시점에 끝나므로, 이 잔차가 곧 후행 무음 구간에 해당한다.

구간 ② 발화 종료 판정에서 TTS 합성 요청 도착까지. STT 최종 전사, LLM 호출, 모듈 간 전달을 포함한다.

구간 ③ TTS 첫 문장의 음성 토큰 생성 완료까지. 문장 단위 스트리밍 구조에서 첫 오디오 청크를 내보낼 수 있는 시점이다.

구간 ③ 이후의 보코더 디코딩, 청크 전송, Unity 버퍼링은 단일 로그에서 직접 측정할 수 없어 합계에 포함하지 않았다. 따라서 아래 수치는 체감 지연의 하한 추정치이다.

6.2.2 구간별 측정 결과

구간별 측정 결과는 표 6.3과 같다.

표 6.3: 구간별 응답 지연(유효 9세션, $n = 47$)

구간	평균(초)	중앙값(초)	90%(초)	최대(초)
① 마지막 음성 → 발화 종료 판정	2.91	2.90	2.94	3.60
② 발화 종료 판정 → TTS 합성 요청	5.79	5.25	10.44	12.08
③ TTS 첫 문장 생성	1.58	1.53	2.12	2.68
①+②+③ 합계	10.28	9.95	14.64	16.26

구간별 기여도는 구간 ②가 56.3%, 구간 ①이 28.3%, 구간 ③이 15.4%로, 전체 지연의 절반 이상이 최종 전사와 LLM 호출에서 발생한다.

구간 ①에서 주목할 점은 47개 턴 전부가 2.8 ~ 3.6s에 분포했다는 사실이다. 현재 설계는 STT 워커가 문장 종료를 감지하면 침묵 임계값을 약 1초로 낮추도록 되어 있고 이번 실험에서도 문장 종료 체크포인트가 79개 발화에서 392건 발생하였다. 그럼에도 실제 답변 종료 시점에 단축된 임계값이 적용된 사례는 한 건도 관측되지 않았다. 즉 체크포인트 기반 임계값 단축이 답변 종료 시점에서는 사실상 작동하지 않았으며, 의도대로 동작했다면 구간 ①에서 약 1.9s를 절감할 수 있었다.

6.2.3 발화 길이에 따른 지연 증가

구간 ②의 표준편차가 크고 90 백분위수가 평균의 약 1.8배에 달한다는 점에서, 이 구간이 고정 비용이 아니라 답변 길이에 의존한다는 가설을 세우고 검증하였다. 발화 시간 t_{speech} 와 구간 ② 지연 L_2 의 관계는 다음과 같다.

$$r = 0.851 \ (n = 47), \quad L_2 \approx 3.48 + 0.073 t_{\text{speech}}.$$

전사 문자 수와의 상관계수도 0.868로 유사하다. 즉 답변이 60초 길어질 때마다 응답 지연이 약 4.39s 증가한다. 고정 성분 3.48s는 표 5.1의 STT 처리 지연 평균 1.68s와 LLM 응답 완료 평균 1.77s의 합인 3.45s와 사실상 일치한다. 이는 백엔드 내부 계측과 크로스 프로세스

타임스탬프 정렬이라는 서로 다른 두 방식으로 측정된 값이 수렴한다는 뜻이며, 본 장의 시계 정렬이 유효함을 뒷받침한다. 개별 턴의 분포와 회귀선은 그림 6.1과 같다.




그림 6.1: 사용자 발화 시간과 구간 ② 지연의 관계

발화 길이 구간별 종단 지연은 0 ~ 15초 답변에서 평균 8.40s($n = 17$), 15 ~ 30초에서 10.00s($n = 14$), 30 ~ 60초에서 10.07s($n = 5$), 60초 이상에서 13.61s($n = 11$)이다. 면접 단계별로 보면 구간 ②는 자기소개 7.30s, 기술 질문 4.86s, 꼬리질문 1 4.75s, 꼬리질문 2 4.51s, 인성 질문 9.49s, 마무리 2.89s로, 답변이 긴 단계에서 뚜렷이 증가한다. 면접이라는 응용에서 가장 중요한 자기소개와 인성 질문 단계에서 지연이 가장 커진다는 점이 문제이다.

6.2.4 기존 측정치와의 관계

표 5.1은 별도의 4개 세션 22턴을 대상으로 마지막 음성 프레임에서 Unity 재생 시작까지 평균 7.64s를 보고하였다. 본 절의 측정값 10.28s와 차이가 나는 원인은 두 가지이다. 첫째는 답변 길이의 차이이다. 본 실험의 답변 프로토콜은 55초 내외의 자기소개와 90초 이상의 인성 질문을 포함하므로 47개 턴의 평균 발화 시간이 기존 측정 대상보다 길고, 앞의 회귀식에 따르면 발화 시간 차이만으로도 수 초의 격차가 발생한다. 둘째는 침묵 임계값 단축의 작동 여부이다. 기존 측정에서 VAD 종료 판단 지연의 중앙값이 1.03s였다는 것은 체크포인트 기반 단축이 상당수 적용되었음을 뜻하나, 본 실험에서는 이 단축이 전혀 적용되지 않아 구간 ①에서만 약 1.9s의 추가 지연이 발생하였다. 따라서 두 측정치는 모순되지 않으며, 7.64s는 짧은 답변이 중심인 조건에서의 값이고 10.28s는 실제 면접 길이의 답변이 포함된 조건에서의 값으로 해석하는 것이 타당하다. 이는 지연을 측정할 때 답변 길이 분포를 반드시 함께 보고해야 한다는 방법론적 시사점을 준다.

6.2.5 목표 대비 달성도와 개선 방향

앞서 정의한 3단계 기준에 대한 달성 여부는 다음과 같다. 종단 지연 중앙값은 목표 2.0s에 대해 9.95s, 95 백분위수는 허용 4.0s에 대해 약 15.4s, 10s 초과 턴 비율은 목표 0%에 대해 46.8%, 발화 종료 판정 지연은 목표 1.5s에 대해 2.91s로 네 항목 모두 미달이다.

측정된 47개 턴 전부가 허용 수준인 4.0s를 초과하였고, 46.8%에 해당하는 22개 턴은 실패 수준인 10s를 넘었다. 현재 구조의 순차 처리 파이프라인으로는 대화형 상호작용에 요구되는 응답성을 만족할 수 없다는 것이 이번 평가의 가장 명확한 결론이다.

측정 결과는 개선의 우선순위도 지시한다. 첫째, 침묵 임계값 단축이 답변 종료 시점에도 유지되도록 상태 관리를 수정하면 약 1.9s를 절감할 수 있다. 이는 코드 수정만으로 달성 가능한 가장 비용이 낮은 개선이다. 둘째, 발화가 끝난 뒤 전체 오디오를 다시 전사하는 현재 방식을 발화 도중 누적된 부분 전사를 확정 결과로 승격하는 증분 전사 방식으로 바꾸면, 발화 길이에 비례하는 성분(평균 2.31s)을 제거할 수 있다. 셋째, 위 두 개선을 모두 적용해도 종단 지연은 약 6.1s로 허용 수준에 도달하지 못하므로, 근본적으로는 대화 경로와 분석 경로를 분리하는 구조가 필요하다. 즉 면접관의 질문·응답 생성은 지연이 최소화된 실시간 경로에서 처리하고, 전사·피쳐 추출·채점은 세션 녹음·녹화를 대상으로 하는 오프라인 배치 경로로 옮기되, 실시간 대응이 필수인 개입 판정만 실시간 경로에 유지한다. 6.3.3절에서 확인하듯 현재 구현의 개입 경로가 이미 1.7 ~ 3.3s의 응답성을 확보하고 있다는 점은 이러한 이중 구조의 실현 가능성을 뒷받침한다.

6.3 문장 단위 스트리밍의 지연 개선 효과

6.3.1 비교 설계와 TTS 합성 성능

면접관 대사는 TTS 워커 내부에서 문장 단위로 분할되어 순차 합성된다. 문장 단위 스트리밍을 적용하면 첫 문장의 합성이 끝나는 즉시 오디오 청크를 내보낼 수 있고, 적용하지 않으면 모든 문장의 합성이 끝날 때까지 기다려야 한다. TTS 워커 로그에는 각 대사의 문장별 생성 시작·완료 시각과 생성 토큰 수가 기록되어 있으므로, 동일한 합성 요청에 대해 첫 문장 완료 시점과 전체 완료 시점을 각각 구하여 두 방식의 차이를 직접 산출할 수 있다. 별도의 재 실험 없이 동일한 데이터에서 적용 전후를 비교한다는 점에서 공정한 비교이다. 분석 대상은 실험 당일 수집된 105건의 합성 요청이며 초기화용 더미 요청은 제외하였고, 포함된 문장은 총 200개이다.

합성 성능은 문장당 생성 시간 평균 1.514s, 초당 생성 토큰 수 평균 71.05, 문장당 토큰 수 평균 107.5, 대사 길이 평균 77.0자였다. 105건 중 1문장이 39건, 2문장이 45건, 3문장이

13건, 4문장이 8건으로 62.9%의 대사가 2문장 이상이어서 스트리밍 효과가 발생할 수 있는 비율이 높다.

6.3.2 개선 효과

적용 전후의 비교 결과는 표 6.4과 같다.

표 6.4: 문장 단위 스트리밍 적용 전후 비교

대상	적용 전(초)	적용 후(초)	절감(초)	절감률
전체 요청 ($n = 105$)	2.947	1.586	1.361	46.2%
다문장 대사 ($n = 66$)	3.745	1.579	2.165	54.3%
종단 기준 ($n = 47$)	11.65	10.28	1.38	11.8%

다문장 대사에서의 절감률은 평균 54.3%, 중앙값 49.5%이며 개별 요청 기준 최소 19.3%에서 최대 83.0%까지 분포한다. 4문장으로 분할된 긴 대사에서는 최대 5.86s가 절감되었다. 종단 지연 기준으로 두 방식을 비교하면 그림 6.2과 같다.




그림 6.2: 문장 단위 스트리밍 적용 전후의 구간별 지연 누적

이 결과는 두 가지를 시사한다. 첫째, 문장 단위 스트리밍은 TTS 단계에 한정하면 매우 효과적인 최적화이다. 둘째, 그럼에도 종단 지연을 기준으로 하면 개선 폭이 11.8%에 그치므로 TTS만 최적화해서는 응답성 목표를 달성할 수 없다. 지연의 84.6%를 차지하는 구간 ①과 ②를 개선하지 않는 한 체감 응답성은 크게 달라지지 않는다.

6.3.3 개입 경로의 2발화 분리 효과

면접관 개입은 LLM 대사 생성보다 먼저 반응하도록, 표정과 상태를 전환하는 템플릿 기반 컷인 대사와 실제 후속 질문을 분리하는 구조를 사용한다. 이는 개입 경로에 적용된 또 하나의 파이프라이닝이다. 세션 JSON에 기록된 개입 이벤트 4건의 지연은 표 6.5과 같다.

주제 이탈형은 부분 전사를 LLM에 보내 관련성을 판정해야 하므로 판정에 평균 891ms가 소요되고 첫 발성까지 평균 2,958ms가 걸린다. 반면 긴 답변형은 LLM 판정이 필요 없어

표 6.5: 개입 경로의 응답 지연(조건 C, 4건)

세션	유형	사유	판정 지연(ms)	첫 발생까지(ms)	대사 완료(ms)
P3-C	REDIRECT	주제 이탈	933	3,269	3,303
P3-C	REDIRECT	주제 이탈	867	2,324	2,353
P1-C	REDIRECT	주제 이탈	873	3,282	3,316
P1-C	CUTOFF	긴 답변	타이머	1,689	1,706

첫 발생까지 1,689ms로 가장 빠르다. 두 경우 모두 허용 수준인 4.0s 이내이며, 일반 질문 경로의 10.28s와 비교하면 3배에서 6배 빠르다. 컷인 대사를 템플릿으로 미리 준비하고 LLM 생성을 뒤로 미루는 설계가 체감 응답성에 직접 기여했음을 보여주는 결과이다.

6.4 음성 인식 성능 평가

6.4.1 평가 프로토콜과 문자 오류율

음성 인식 성능은 참가자 응답 대본을 참조 텍스트로 삼아 평가하였다. 다만 참가자가 대본을 그대로 읽지 않고 요약하거나 바꾸어 말한 턴에서는 참조 텍스트와의 차이가 인식 오류인지 발화 변형인지 구분할 수 없다. 5.6절은 예상 질문과 실제 질문의 흐름이 일치하는 턴을 기준으로 선별하였으나, 본 절에서는 발화 변형의 영향을 더 강하게 통제하기 위해 다음 절차를 사용하였다.

첫째, 대본이 존재하는 단계인 자기소개와 인성 질문의 사용자 턴 17개를 후보로 삼는다. 둘째, 참조 텍스트와 전사 결과를 모두 공백과 문장부호를 제거하고 유니코드 정규화한다. 셋째, 전사 결과의 문자 수가 참조 텍스트의 90% 이상인 턴만을 완독 턴으로 선별한다. 이는 참가자가 대본을 실질적으로 끝까지 발화했음을 의미한다. 넷째, 완독 턴에 대해 문자 단위 편집 거리를 계산하여 문자 오류율을 산출한다. 이 기준으로 17개 후보 중 9개 턴이 선별되었고, 참조 텍스트 총 3,920자가 평가에 사용되었다. 선별되지 않은 8개 턴은 참가자가 대본의 25 ~ 72%만 발화한 경우이다.

총합 기준 문자 오류율은 9.34%, 턴별 평균은 9.51%, 범위는 2.6%에서 16.1%이다. 기준인 10% 이하를 총합 기준으로는 만족하지만, 9개 턴 중 4개가 10%를 초과하여 안정적으로 달성했다고 보기는 어렵다. 이 값이 5.6절의 참고값 5.86%보다 높은 것은 측정 대상이 다르기 때문이다. 5.6절은 참가자 1명이 조용한 환경에서 수행한 4개 세션의 19개 턴을 대상으로 한 반면, 본 절은 참가자 3명이 노트북 마이크와 원격 오디오 경로를 경유한 대면 실험의 9개 턴을 대상으로 한다. 화자와 녹음 경로가 다양해질수록 오류율이 높아진다는 점을 보여주는 결과이며, 두 값 모두 대본을 참조 텍스트로 사용한 참고값이라는 한계를 공유한다.

표 6.6: 완독 턴의 문자 오류율($n = 9$)

참가자	조건	단계	참조 길이(자)	편집 거리	CER
P1	C	자기소개	199	14	7.0%
P2	A	자기소개	376	33	8.8%
P2	A	인성 질문	541	14	2.6%
P2	B	자기소개	376	59	15.7%
P2	B	인성 질문	541	60	11.1%
P2	C	자기소개	376	46	12.2%
P2	C	인성 질문	541	32	5.9%
P3	A	인성 질문	485	78	16.1%
P3	B	인성 질문	485	30	6.2%
총합			3,920	366	9.34%

6.4.2 전문 용어 인식률

발화 변형의 영향을 받지 않는 지표로, 참조 텍스트에 포함된 전문 용어가 전사 결과에 올바른 형태로 나타났는지를 별도로 집계하였다. 판정 기준은 해당 용어의 표준 한글 음차 표기 또는 영문 표기가 전사 결과에 존재하는지 여부이다.

표 6.7: 전문 용어 인식률(완독 턴 기준)

용어	발화	정인식	인식률	오인식 형태
Kotlin	3	0	0%	코틀링, 포틀링(2회)
Spring Boot	3	1	33%	스프링 보트(2회)
Kubernetes	3	2	67%	코버네티스
Java / MySQL / Redis / Kafka	12	12	100%	—
Photon	1	1	100%	—
라벨링 / 감성 분석	10	10	100%	—
지하 10층 / 풍림화산 전쟁	2	2	100%	—
합계	34	28	82.4%	

용어를 성격별로 나누면 차이가 뚜렷하다. 영문 기술 고유명사인 Kotlin, Java, Spring Boot, MySQL, Redis, Kafka, Kubernetes, Photon은 22회 중 16회만 정인식되어 인식률이 72.7%인 반면, 한국어 도메인 용어와 고유명사는 12회 전부 정인식되었다. 기준인 90%에 미달하며, 특히 영문 기술 고유명사에서 27.3%의 오인식이 발생하였다. 오인식 패턴을 보면 종성이 유사한 음절로 치환되는 경우와 모음이 치환되는 경우가 주를 이룬다. 한국어 화자가 영문 용어를 음차 발음할 때 발생하는 음운 변이를 모델이 충분히 학습하지 않은 것으로 보인다. 또한 동일 참가자가 동일 대본을 발화했음에도 P2의 Spring Boot는 조건 C에서만 정인식되었고 Kubernetes는 조건 B에서만 오인식되어, 오인식이 결정적이지 않고 발화 시점의 조음과 환경에 따라 변동함을 확인하였다.

6.4.3 오류 유형과 하류 영향

전사 오류가 단순한 표기 문제에 그치지 않고 후속 처리에 영향을 미친 사례가 확인되었다.

첫째는 고유명사의 반복 오인식이다. P3의 인성 질문 답변에서 “팀원”이 조건 A에서는 “디모언”, 조건 B에서는 “디먼”으로 전사되었고, P2의 조건 C 세션에서는 “팀원”이 “T1”으로 전사되었다. 협업 경험을 서술하는 인성 답변에서 “팀원”은 핵심 명사인데, 이것이 무의미한 문자열로 바뀌면 LLM의 내용 평가가 왜곡될 수 있다.

둘째는 전사 오류가 개입 오답으로 이어진 연쇄이다. P3의 조건 C 세션에서 참가자는 “그냥 어디선가 참고해서 설정값 정도만 가져다 쓰고”라고 발화하였으나, 부분 전사 결과는 “그냥 어디선가 잠구해서 설정값 정도만 가져다 쓰고”였다. 이 부분 전사가 주제 이탈 판정용으로 백엔드 LLM에 전달되었고, LLM은 이를 주제 이탈로 판정하여 면접관이 답변을 중단시켰다. 실제 답변은 질문에 직접 대응하는 답변이었으므로 이는 오답이다.

셋째는 부분 전사와 최종 전사의 품질 차이이다. 위 사례에서 최종 전사는 “잘 모르겠습니다”로 문장이 정상 종결되었으나, 판정에 사용된 부분 전사는 문장 중간에서 잘린 상태였다. 개입 판정이 부분 전사에 의존하는 현 구조의 구조적 취약점이다.

6.5 음성 피쳐 성능 평가

음성 피쳐는 유효 9세션 54개 턴 중 53개인 98.1%에서 모두 산출되었다. 산출되지 않은 1개 턴은 P1의 조건 C 세션에서 긴 답변형 개입으로 중단된 인성 질문 턴이며, 발화가 확정되지 않아 값이 기록되지 않았다. 즉 음성 피쳐는 측정 자체의 실패율이 사실상 0에 가깝다.

주요 피쳐의 분포는 표 6.8과 같다.

표 6.8: 음성 피쳐 분포($n = 53$)

피쳐	평균	중앙값	최소	최대	비고
발화 시간(초)	30.36	20.39	1.45	104.47	단계별 설계 차이를 반영
초당 문자 수	7.23	7.50	3.46	9.67	기준값 5.0자
의미 있는 침묵 횟수	13.51	7	1	59	발화 시간에 비례
평균 음량	0.031	0.026	0.022	0.051	기준값 0.1
음량 분산	0.0001	0.0000	0.0000	0.0011	감점 임계 0.05
낮은 음량 비율	0.000	0.000	0.000	0.000	53턴 전부 0
반응 시간(초)	2.40	2.28	0.93	7.99	기준값 1.5 또는 3.5

측정 결과는 4장 4.5.1절의 점수 산식과 대조할 때 세 가지 문제를 드러낸다.

첫째, 평균 음량의 기준값이 실측 분포와 어긋난다. 산식은 기준 음량 0.1에서 허용 오차 0.05를 적용하는데, 실측 평균 음량은 0.022에서 0.051 사이이고 53턴 중 51턴이 0.05 미만이다. 그 결과 모든 턴에서 $|r - 0.1|$ 이 0.049에서 0.078 사이에 놓여 감점이 0 또는 1로만

결정되고, 9개 세션의 최종 음량 점수가 모두 9점으로 동일해졌다. 또한 음량 분산의 실측 평균은 0.0001로 감점 임계인 0.05보다 두 자릿수 이상 작아 이 조건은 한 번도 발동하지 않았다.

둘째, 낮은 음량 비율이 53턴 전부 0.000으로 기록되어 해당 감점 규칙이 사문화되었다. 임계값이 실제 음량 분포보다 훨씬 낮게 설정되어 있을 가능성이 높다.

셋째, 반응 시간의 실측 평균은 2.40s로 기준값 3.5s와의 차이가 1.1s이며 감점 단위인 1.5s보다 작다. 따라서 대부분의 턴에서 감점이 발생하지 않아 반응 속도 항목이 9점에서 10점 사이에 고정되었다.

발화 종료 판정 자체는 안정적이었다. 47개 정상 턴의 후행 무음은 전부 2.8 ~ 3.6s에 분포하고 표준편차가 0.13s로, 종료 판정이 일관되게 기본 침묵 임계값에 의해 결정되었다. 발화 도중의 짧은 침묵을 답변 종료로 오인하여 답변이 끊긴 사례는 한 건도 없었다. 즉 현재 VAD 설정은 짧은 침묵을 종료로 오인하지 않는다는 요구는 만족하지만 발화 종료를 빠르게 감지한다는 요구는 만족하지 못하는 보수적 설정이다.

6.6 영상 피쳐 성능 평가

6.6.1 검출 및 처리 성능

영상 분석 워크의 처리 성능은 유효 9세션 59개 구간 기준으로 실효 프레임률 8.03 fps, 얼굴 검출률 99.91%, 상체 검출률 100.0%, 캘리브레이션 유효 구간 100.0%이다. 제외된 세션을 포함한 16회 실행 85개 구간 기준으로는 각각 7.62 fps, 94.0%, 94.1%이다.

유효 세션에 한정하면 얼굴과 상체 검출은 거의 완벽하며 캘리브레이션도 전 구간에서 유효하였다. Unity Editor 로그 기준 16회의 캘리브레이션 시도 중 성공은 15회로 93.8%이고, 성공한 경우 3초 동안 23개에서 24개의 샘플이 수집되었다.

문제는 프레임률이다. 4.5.2절의 목표 처리율은 10 fps였으나 실측은 8.03 fps로 목표의 80.3%에 머물렀다. Face Landmarker와 Pose Landmarker를 CPU에서 함께 실행하는 구성의 처리 한계로 보인다. 프레임률 저하는 프레임 카운트 기반 피쳐의 시간 해상도를 낮추고 짧은 구간의 표본 수를 줄인다. 실제로 4.66 ~ 4.69s인 개입 직후 반응 구간에서 확보된 프레임은 38개 수준이다. 한편 검출 실패는 특정 실행에 집중되어, 제외된 13시 12분 세션에서는 5개 구간 전부가 얼굴 검출률 0%, 실효 프레임률 1.0 ~ 1.1 fps를 기록하였다. 영상 분석의 실패는 점진적이 아니라 세션 단위로 전면 발생하므로 탐지는 쉬우나 세션 전체를 폐기해야 하는 비용을 수반한다.

6.6.2 시선 피처의 참가자 간 체계적 편향

참가자별 시선 유지 비율의 평균은 P1이 0.639(20구간, 중앙값 0.693), P2가 0.714(17구간, 중앙값 0.801), P3가 0.076(22구간, 중앙값 0.023)이다.

세 참가자는 동일한 응답 프로토콜을 수행하였고 모두 화면의 면접관을 바라보도록 안내 받았다. 그럼에도 P3의 시선 유지 비율은 P1과 P2의 약 9분의 1 수준이며 22개 구간 중 11개에서 0.000을 기록하였다. P3의 얼굴 검출률은 100%였고 캘리브레이션도 전 구간 유효하였으므로 검출 실패가 아니라 시선 판정 자체의 편향이다. 머리 흔들림 지표인 yaw 표준편차의 실측 평균은 3.09° 로 감점 임계 5.0보다 작아 시선 점수는 사실상 정면 응시 비율 r_g 만으로 결정되는데, r_g 의 임계가 0.30이므로 P3는 거의 모든 구간에서 0점을 받는다. 원인으로서는 화면 대비 웹캠의 상하 위치와 안경 착용 여부에 따라 캘리브레이션 기준점이 실제 응시 방향과 어긋났을 가능성이 높다. 현재 구현은 캘리브레이션 성공 여부만 판정하고 그 결과가 타당한 범위에 있는지는 검증하지 않는다.

이 편향의 영향은 최종 점수에서 직접 확인된다. 시선 항목 점수의 참가자별 평균은 P1과 P2가 각각 7.33점, P3가 0.33점이며, 총점 평균은 P1이 69.3점, P2가 66.7점, P3가 55.3점이다. P1과 P3의 격차 14.0점 중 7.0점, 즉 정확히 절반이 시선 항목 하나에서 발생하였다. 동일한 대본으로 동일한 품질의 답변을 수행했음을 감안하면 이 격차는 면접 수행 능력의 차이가 아니라 측정 환경의 차이가 점수로 전이된 것이다. 따라서 현재 시선 피처는 동일 사용자의 세션 내 상대 비교에만 사용할 수 있고 사용자 간 절대 비교나 점수 산정의 근거로 사용해서는 안 된다.

6.6.3 제스처 피처의 측정 실패와 표정 피처의 포화

손 사용 비율은 유효 9세션 59개 구간 중 52개 구간인 88.1%에서 정확히 0.000이었다. 이는 참가자가 손을 사용하지 않았기 때문이 아니라 손이 640×480 웹캠의 화각 밖에 있었기 때문이다. 참가자는 노트북 앞에 착석하여 상반신 상부만 프레임에 들어오는 구도였고, 이 구도에서는 책상 위 손동작이 촬영되지 않는다. 얼굴 접촉 횟수도 59개 구간 전부 0이어서 관련 감점 규칙이 한 번도 발동하지 않았다. 4.5.2절의 산식에서 손 사용 비율이 0.02 이하이면 점수가 2점으로 고정되므로, 손 사용 항목은 9세션 중 7세션에서 2점으로 고정되어 모든 사용자에게 동일한 감점을 부여하는 상수로 작동하였다. 즉 현재 제스처 피처는 측정 실패 상태이며 점수에 포함되어서는 안 된다.

표정과 자세 피처는 반대 방향으로 포화되었다. 표정 변화량의 실측 평균은 0.0296으로 감점 임계 0.012보다 크고 임계 미만 구간은 59개 중 1개뿐이며, 미소 비율의 실측 평균은 0.0036으로 가산 조건 0.15에 한 번도 도달하지 못하여 표정 점수가 9세션 모두 10점으로

동일하게 산출되었다. 상체 흔들림도 실측 평균이 0.0243으로 감점 임계 0.030보다 작고 초과 구간이 59개 중 17개에 그쳐 대부분의 세션이 10점을 받았다.

6.6.4 지속 시간 교란

자세 흔들림과 표정 변화량은 구간 내 표준편차 또는 분산으로 계산되므로 구간이 길수록 값이 커지는 경향이 구조적으로 존재한다. 인성 질문 단계의 9개 구간은 길이가 64.3s에서 109.1s까지 분포하며 개입으로 중단된 구간과 정상 구간의 길이가 다르다. 따라서 두 구간을 직접 비교하는 것은 타당하지 않으며, 조건 간 비교는 동일 단계와 동일 위상 내에서만 수행해야 한다. 본 장의 모든 조건 간 비교는 이 원칙을 따랐다.

6.7 점수 산정의 타당성 분석

6.7.1 검증 설계와 단계별 점수

면접 평가 전문가의 참여 없이 점수의 절대적 타당성을 검증하는 것은 불가능하다. 대신 본 절에서는 답변 프로토콜이 사전에 설계한 품질 순위를 채점 결과가 재현하는지를 기준으로 구성 타당도를 검토한다. 표 6.1에 따르면 기대되는 품질 순위는 자기소개와 인성 질문이 가장 높고, 기술 질문, 꼬리질문 1, 꼬리질문 2의 순으로 낮아진다. 채점 대상 단계는 기술 질문, 꼬리질문 1, 꼬리질문 2, 인성 질문의 4개이며 9세션에서 총 36개 턴이다.

표 6.9: 단계별 LLM 답변 점수(0 ~ 100점)

단계	설계 의도	턴 수	평균	중앙값	범위	40점 미만
기술 질문	의도적 저품질	9	38.3	40	30-45	22%
꼬리질문 1	의도적 저품질	9	22.2	20	0-40	56%
꼬리질문 2	주제 이탈 포함	5	4.0	0	0-20	100%
인성 질문	준비된 고품질	3	0.0	0	0-0	100%

의도적 저품질로 설계한 세 단계에서는 설계한 품질 순위가 정확히 재현되었다. 답변이 점점 부실해지고 마지막에는 주제를 이탈하는 흐름을 채점기가 단조적으로 반영한 것이다. 이는 LLM 채점기가 답변 품질의 상대적 서열을 판별하는 능력을 갖추고 있음을 보여주는 긍정적 결과이다.

그러나 인성 질문에서 결과가 역전된다. 인성 질문 답변은 갈등 상황, 대응, 결과, 교훈을 갖춘 준비된 90초 분량의 답변이었음에도 채점된 3건 전부가 0점을 받았다. 설계상 가장 높은 점수를 받아야 할 단계가 가장 낮은 점수를 받은 것이다. 대화 전문을 검토한 결과 이 답변들은 구조적으로 온전하며 질문에 정확히 대응하고 있다. 따라서 0점은 답변 품질의 반영이 아니라, 채점 기준이 직무 관련성과 기술적 구체성 측에 편향되어 기술 내용이 없는

인성 답변을 평가하지 못한 결과로 해석된다. 부록 B의 채점 프롬프트가 모든 단계에 동일한 채점 축을 적용한 것이 원인으로 보인다. 이는 점수 타당성에 대한 가장 심각한 발견이다. 실제 사용자가 인성 질문에 훌륭하게 답변하더라도 0점을 받고, 그 결과 면접관이 부정 페르소나로 전환되어 부당한 압박을 받게 되기 때문이다.

6.7.2 채점 결측률과 점수 해상도

채점 대상 36개 턴 중 실제로 점수가 산출된 턴은 26개인 72.2%이며, 10개 턴인 27.8%에서 점수가 산출되지 않았다. 백엔드 로그에서 해당 턴의 행동 패킷은 점수 필드가 -1로 기록되어 있다. 결측은 특정 단계에 집중되지 않고 세션 전반에 흩어져 있었으며, 세션별 채점 성공 턴 수는 4개가 2세션, 3개가 4세션, 2개가 3세션이었다. 결측이 발생하면 해당 턴의 점수가 페르소나 산정에 반영되지 않으므로 면접관의 태도 변화가 답변 품질을 일관되게 추종하지 못하는 원인이 된다. 결측의 원인은 로그만으로 특정하기 어려우나, LLM 응답의 파싱 실패 시 기본 응답으로 대체하는 처리가 점수 필드를 보존하지 않는 구조일 가능성이 높다.

산출된 26개 점수가 취한 값은 0, 20, 30, 40, 45의 다섯 가지뿐이었다. 0 ~ 100점 척도임에도 실질 해상도가 극히 낮으며 대부분이 10의 배수에 집중되었다. LLM이 연속적인 점수를 산출하기보다 몇 개의 전형적인 값에 고정되는 경향을 보인 것이다.

더 중요한 문제는 값의 분포가 페르소나 임계값과 충돌한다는 점이다. 표 4.4의 규칙에 따르면 40점 이상 70점 미만은 중립, 40점 미만은 부정으로 분류된다. 그런데 26개 점수 중 10개인 38.5%가 정확히 40점이었다. 40점은 부정 페르소나 경계의 바로 위이므로 이 턴들은 모두 중립으로 분류되었다. 이 문제의 실제 영향은 6.8.4절에서 확인한다.

개선 방향은 세 가지이다. 첫째, 채점 프롬프트에 점수 구간별 기준을 명시하여 중간값 산출을 유도한다. 둘째, 임계값을 점수 분포의 실제 최빈값과 겹치지 않도록 조정한다. 셋째, 단일 턴 점수가 아니라 최근 턴의 이동 평균이나 누적 이력으로 페르소나를 결정하여 경계값 하나에 태도 전체가 좌우되지 않도록 한다.

6.7.3 평가 항목의 변별력

최종 결과 화면에 표시되는 10개 항목 점수의 9세션 분포는 표 6.10과 같다.

10개 항목 중 자세 안정성, 표정 변화, 목소리 크기, 반응 속도의 4개는 표준편차가 0.31 이하로 사실상 변별력이 없고, 표정 변화와 목소리 크기는 9세션 모두 동일한 값을 기록하였다. 손 사용은 측정 실패 상태이다. 결과적으로 변별에 기여하는 항목은 시선 처리, 목소리 빠르기, 필러 단어, 답변의 정확도 4개뿐이며 이 중 시선 처리는 환경 편향을 포함한다. 변별력이 없는 항목이 모두 9점에서 10점에 고정되어 있다는 점도 문제이다. 총점 100점 중 약 39점이 사실상 무조건 부여되는 구조이므로 총점의 하한이 인위적으로 높아진다. 실제로 9

표 6.10: 10개 평가 항목의 분포와 변별력($n = 9$ 세션)

항목	평균	중앙값	표준편차	범위	변별력
시선 처리	5.00	6	3.68	0-10	높음(환경 편향 포함)
손 사용	2.78	2	1.87	2-8	낮음(7/9세션이 2점)
자세 안정성	9.89	10	0.31	9-10	없음
표정 변화	10.00	10	0.00	10-10	없음
목소리 크기	9.00	9	0.00	9-9	없음
목소리 빠르기	2.56	2	1.50	0-5	보통
답변 길이	5.44	5	0.83	4-7	낮음
필러 단어 여부	6.78	7	1.13	5-8	보통
답변의 정확도	2.44	2	1.07	1-4	보통
답변 반응 속도	9.89	10	0.31	9-10	없음
총점	63.78	68	6.44	53-70	—

세션의 총점은 53점에서 70점 범위에 머물렀고, 의도적으로 부실하게 답변한 세션에서도 50점대 이하로 내려가지 않았다.

6.7.4 총점의 구성 타당성

조건별 총점 평균은 조건 A가 63.7점, 조건 B가 64.0점, 조건 C가 63.7점으로 차이가 0.3점에 불과하다. 이는 설계상 타당한 결과이다. 세 조건은 면접관의 반응 방식만 다를 뿐 답변 내용은 동일하므로 답변을 평가하는 총점이 조건에 따라 달라져서는 안 되며, 채점 결과가 조건에 오염되지 않았다는 점에서 긍정적이다. 반면 참가자 간 차이는 14.0점에 달하고, 그 절반이 시선 항목 하나에서 발생한다.

종합하면 현재 총점은 다음 성질을 가진다. 면접관의 태도 조건에 오염되지 않는다는 점은 타당하고, 답변 품질의 상대적 서열을 저품질 구간에서 부분적으로 반영한다는 점도 타당하다. 그러나 준비된 인성 답변을 평가하지 못하고, 사용자 간 비교에 측정 환경 편향이 지배적으로 개입하며, 10개 항목 중 4개가 무변별 상수로 작동하여 총점 하한을 인위적으로 높인다는 점은 부당하다. 따라서 현재 총점은 동일 사용자가 반복 연습하며 자신의 변화를 추적하는 용도로는 제한적으로 사용할 수 있으나, 사용자 간 비교나 절대적 수준 판정에는 사용할 수 없다. 결과 화면에도 이 취지를 명시할 필요가 있다.

6.8 면접관 개입의 적절성 평가

6.8.1 정답 정의와 게이트 차단 구조

표 6.1의 답변 프로토콜에 따라 각 세션에는 꼬리질문 2 후반부의 명시적 이탈 발화와 인성 질문의 90초 초과 답변이라는 두 개의 개입 대상 이벤트가 계획적으로 포함된다. 긴 침묵은 프로토콜에 없으므로 이 유형의 발동은 모두 오탐으로 간주한다. 평가는 트리거와 판정기의

분류 성능을 보는 판정기 수준과, 게이트 통과까지 포함하여 실제 개입 실행 여부를 보는 중단 수준으로 나누어 수행하며 시스템의 유용성을 결정하는 것은 후자이다. 개입은 여러 단계의 게이트를 순차 통과해야 실행된다. 16회 실행 전체에서 기록된 게이트 판정 44건의 분포는 표 6.11과 같다.

표 6.11: 게이트별 차단 현황(16회 실행, 44건)

게이트	차단 조건	REDIRECT	CUTOFF	계
조건	조건 A·B에서는 개입 비활성	7	2	9
단계	대상 단계 외(자기소개·마무리)	10	2	12
페르소나	페르소나가 부정이 아님	6	1	7
유예 시간	발화 시작 후 T_{grace} 미경과	7	—	7
재답변	개입 직후 재답변 구간	3	—	3
관련성	LLM이 온토폭으로 판정	2	—	2
(통과)	개입 실행	3	1	4

주제 이탈형 후보 38건 중 LLM 판정 단계까지 도달한 것은 5건인 13.2%이며 나머지 86.8%는 LLM 호출 없이 사전 게이트에서 차단되었다. 이 구조는 호출 비용과 오탐을 동시에 줄인다. 실제로 자기소개와 마무리 단계에서 발생한 12건의 후보는 전부 단계 게이트에서 차단되었고 이들이 통과했다면 모두 부적절한 개입이 되었을 것이다. 다만 페르소나 게이트에서 차단된 7건 중 일부는 6.8.4절에서 보듯 차단되지 말았어야 할 정답 이벤트였다. 즉 현재 게이트 구조는 정밀도를 높이는 대가로 재현율을 희생하고 있으며 그 희생이 예상보다 크다.

6.8.2 긴 답변과 긴 침묵 트리거의 성능

긴 답변 트리거는 Unity 측 타이머로 구현되어 결정적으로 동작한다. 유효 9세션의 인성 질문 답변 중 90초를 초과한 것은 P2-B의 97.5s, P2-A의 92.7s, P2-C의 104.5s, P1-C의 90.0s의 4건이며 이 4건 모두에서 트리거가 발동하였다. 90초에 미달한 P3-A의 88.5s, P1-B의 83.8s, P3-B의 83.1s, P1-A의 69.5s, P3-C의 64.1s에서는 발동하지 않았다. 즉 정답 4건, 오탐 0건, 미탐 0건으로 정밀도와 재현율이 모두 100%이다.

88.5s 답변에서 발동하지 않고 90.0s 답변에서 발동한 것은 임계값 T_{long} 이 정확히 동작했음을 보여준다. 트리거 자체는 신뢰할 수 있으며 문제는 트리거 이후의 게이트에 있다.

긴 침묵 트리거는 16회 실행 중 2회 발동하였고 두 건 모두 마무리 단계에서 발생하여 단계 게이트에서 차단되었다. 프로토콜상 긴 침묵은 계획되지 않았으므로 두 건 모두 오탐이며, 게이트가 이를 전부 차단하여 실제 개입으로 이어지지 않았다. 다만 두 건의 발동 시점은 모두 경과 시간 15.0s였는데, 이는 4.5.3절에 기술한 현재 설정값 $T_{\text{silence}} = 20\text{s}$ 와 다르다. 실험 당시 구현에는 15s가 적용되어 있었고 이후 값이 조정되었다. 유효 9세션에서는 이 트리거가 한 번도 발동하지 않아 긴 침묵형 개입은 이번 실험에서 검증되지 않았다.

6.8.3 주제 이탈 판정기의 성능

LLM 주제 이탈 판정기가 실제로 호출된 것은 5건이다. 각 건의 질문과 부분 전사 내용을 검토하여 정답을 부여한 결과는 표 6.12과 같다.

표 6.12: 주제 이탈 판정기의 분류 결과($n = 5$)

세션	단계	부분 전사 요지	실제	판정	분류
P3-C	꼬리1	선택 기준 질문에 “잘 모르겠다, 설정값만 가져다 썼다”	온토픽	이탈	오탐
P3-C	꼬리2	대용량 처리 전략 질문에 “비슷한 방식, 이런저런 시도”	온토픽	이탈	오탐
P3-C	인성	협업 갈등 사례 서술	온토픽	온토픽	정부
P1-C	꼬리1	Photon 지연 측정 질문에 “팀 프로젝트, 일정이 빡빡”	이탈	이탈	정탐
P1-C	인성	협업 갈등 사례 서술	온토픽	온토픽	정부

정탐 1건, 오탐 2건, 정부 2건, 미탐 0건으로 정밀도는 33.3%, 재현율은 100%, 정확도는 60%이다. 표본이 5건에 불과하므로 이 비율은 안정적인 추정치가 아니며 신뢰구간이 매우 넓다. 그러나 오탐 2건의 내용은 진단적 가치가 크다.

두 오탐 모두 질문에 대응하지만 내용이 부실한 답변을 이탈로 오판한 사례이다. 표 6.1에서 꼬리질문 1은 “모른다” 계열의 저품질 답변으로 설계되어 있는데 판정기는 이를 주제 이탈로 분류하였다. 즉 판정기가 주제 관련성과 내용 충실도를 구분하지 못하고 있으며, 부록 B의 판정 프롬프트가 두 개념을 명시적으로 분리하지 않은 것이 원인으로 보인다. 첫 번째 오탐에는 6.4.3절의 전사 오류가 개입하여 전사 품질 저하가 개입 오탐으로 증폭되는 연쇄가 관측되었다. 두 번째 오탐은 부작용도 낳았다. 프로토콜상 P3의 꼬리질문 2에는 날씨 화제로의 이탈이 예정되어 있었으나, 판정기가 그 이전 온토픽 구간에서 개입을 발동시켜 정답 이벤트가 발화될 기회 자체가 사라졌다.

6.8.4 중단 성능과 미탐 사례

게이트 통과까지 포함한 중단 성능을 조건 C의 유효 3세션에 대해 집계한 결과는 다음과 같다. P1-C에서는 주제 이탈과 90.0s의 긴 답변이 모두 발생하였고 둘 다 검출되었다. P2-C에서는 주제 이탈과 104.5s의 긴 답변이 발생하였으나 둘 다 검출되지 않았다. P3-C에서는 개입이 정답 이벤트보다 먼저 발동하여 두 정답 이벤트가 모두 발생하지 못한 대신 오탐 2건이 기록되었다.

정탐 2건, 오탐 2건, 미탐 2건으로 정밀도 50.0%, 재현율 50.0%, F1 점수 50.0%이다. 조건 C로 실행되어 정상 종료한 4개 실행까지 확장하면 미탐이 2건 추가되어 재현율은 33.3%로 낮아진다.

미탐 2건은 모두 P2의 조건 C 세션에서 발생하였으며 원인은 단일하다. 이 세션에서 기술 질문과 꼬리질문 1이 모두 40점을 받아 페르소나가 끝까지 중립을 유지했고, 개입 게이트의 전제 조건인 부정 페르소나가 성립하지 않았다. 백엔드 로그에는 인성 질문 단계에서 긴 답변 트리거가 발동했으나 페르소나 게이트에서 차단된 기록이 남아 있다. 참가자는 계획대로 주제를 이탈했고 104.5s 동안 답변을 이어갔음에도 시스템은 두 이벤트를 모두 놓쳤다. 인과 연쇄는 다음과 같다.

LLM 점수가 10 단위로만 산출됨 → 40점이 반복 출현 → 40점은 부정 페르소나 임계값의 바로 위 → 페르소나가 중립 유지 → 개입 게이트 전제 조건 미충족 → 정답 이벤트 2건 모두 미탐

즉 개입 기능의 신뢰성은 개입 판정 로직 자체보다 상류의 채점 해상도에 의해 결정된다. 개입 성능을 개선하려면 판정 프롬프트보다 채점 프롬프트와 임계값 설계를 먼저 손보아야 한다는 것이 이번 평가의 결론이다.

개입이 실행된 4건의 후속 처리는 4.5.3절의 설계대로 동작하였다. 잘린 답변은 폐기되지 않고 부분 전사를 대상으로 채점된 뒤 재답변 점수와 0.5씩의 가중치로 결합되었고, 3건인 주제 이탈형은 단계를 유지한 채 재답변을 받았으며 1건인 긴 답변형은 다음 단계로 진행하였다. 재답변 게이트가 3건의 추가 개입 후보를 차단하여 연속 개입을 방지하였고, 개입 직후 반응 측정 구간도 4건 모두 4.66 ~ 4.69s로 정상 기록되었다. 다만 표본이 4건이어서 개입 전후 행동 변화의 통계적 분석은 수행하지 않았다.

6.9 실험 조작 점검

조건 간 비교가 의미를 가지려면 각 조건이 의도한 대로 동작해야 한다. 조건 A는 페르소나가 고정되어야 하고 조건 B와 C는 답변 점수에 따라 페르소나가 전환되어야 한다. 백엔드 로그에 기록된 행동 패킷의 페르소나 값을 세션별로 추적한 결과는 표 6.13과 같다.

표 6.13: 세션별 페르소나 전이

세션	페르소나 진행	전이 횟수	조작 성립
P1-A	중립 ×5	0	성립
P2-A	중립 ×5	0	성립
P3-A	중립 ×5	0	성립
P1-B	중립 ×4 → 부정	1	성립
P2-B	중립 ×5	0	불성립
P3-B	중립 ×2 → 부정 ×3	1	성립
P1-C	중립 → 부정 ×4	1	성립
P2-C	중립 ×5	0	불성립
P3-C	중립 → 부정 ×5	1	성립

조건 A의 3세션은 모두 의도대로 중립을 유지하였다. 그러나 조건 B와 C의 6세션 중 2세션에서 페르소나 전이가 전혀 발생하지 않아 실질적으로 조건 A와 구분되지 않는 상태로 진행되었다. 조작 성립률은 66.7%이며 원인은 6.7.2절의 40점 경계 문제이다. 또한 9세션 전체에서 긍정 페르소나는 한 번도 발생하지 않았다. 답변 프로토콜이 의도적 저품질이므로 자연스러운 결과이지만 3단계 페르소나 중 1단계는 검증되지 않은 셈이다. Unity에 전달된 연속 감정값도 0.00, -0.20, -0.60, -0.80, -1.00의 5개 값만을 취하여, 연속값으로 정의된 축이 실제로는 소수의 이산값으로만 구동되었다.

이상의 결과는 조건 간 비교의 신뢰성을 직접 제약한다. 9세션 중 2세션에서 조작이 성립하지 않았고, 조건 순서가 완전한 라틴 방격을 이루지 못했으며, 조건당 세션 수가 3개에 불과하다. 따라서 본 실험은 조건 간 효과를 통계적으로 검정하기에 충분하지 않으며, 시스템이 조건별로 설계대로 동작하는지를 확인하는 기능 검증의 성격에 머문다.

6.10 데이터 유효성을 위협한 결함

6.10.1 자연 전사 귀속 오류

인성 질문처럼 긴 답변에서는 STT 최종 전사가 완료되기까지 10초 이상이 소요될 수 있다. 이 사이에 면접 단계가 다음으로 전이되면 뒤늦게 도착한 전사 결과가 다음 단계의 답변으로 기록된다. 정상 종료한 11개 실행 중 2건인 18.2%에서 이 결함이 확인되었다. 판정 기준은 마무리 단계의 전사 길이가 200자를 초과하거나 발화 시간이 30초를 초과하는 경우이며, 해당 세션들의 마무리 단계에는 인성 질문의 답변 내용이 그대로 기록되어 있었다.

13시 44분 세션은 인성 질문에 36자와 6.6s가, 마무리에 618자와 86.8s가 기록되어 재실행 후 분석에서 제외하였다. 14시 42분 세션은 인성 질문에 18자가, 마무리에 720자와 90.0s가 기록되었다. 이 세션은 긴 답변형 개입으로 인성 질문 답변이 90초에 중단된 직후 중단 이전 구간의 최종 전사가 마무리 단계에 도착한 경우이며, 개입이 정상 작동한 유일한 조건 C 세션이어서 제외하기 어려웠으므로 결함을 명시한 상태로 분석에 포함하였다.

그 결과 해당 세션에서는 마무리 단계의 답변 길이가 720자와 90초로 기록되어 답변 길이 항목과 반응 속도 항목에 실제보다 유리하게 반영되었고, 총점 70점은 9세션 중 최고값이다. 즉 이 세션의 총점은 결함에 의해 부풀려진 값이며, 조건 C의 대표값으로 사용할 때 주의가 필요하다. 근본 해결책은 발화 식별자를 기준으로 전사 결과를 소급 귀속시키고, 최종 전사 대기 시간을 발화 길이에 비례하여 동적으로 늘리는 것이다.

6.10.2 세션 식별자 오염과 결함의 영향 범위

모든 실험이 고정된 세션 식별자를 사용하여, 영상 피쳐 CSV에 실험 전날 수행한 사전 점검 기록 9건이 당일 기록 85건과 구분되지 않은 상태로 누적되었다. 본 분석에서는 기록 시각으로 날짜를 필터링하여 분리하였으나, 참가자와 조건별 식별자를 사용하지 않으면 사후 분석에서 데이터 혼입을 배제하기 어렵다. 세션 JSON 파일명도 참가자 정보를 포함하지 않아 지원 기업과 직무 정보로 참가자를 역추적해야 했다.

위 결함이 본 장의 결론에 미치는 영향은 다음과 같다. 6.2절부터 6.4절까지의 지연, TTS, STT 측정은 세션 귀속과 무관한 프로세스 내부 시각과 전사 텍스트에 기반하므로 영향이 없다. 6.5절과 6.6절의 피쳐는 톤 구간 단위로 기록되며 귀속 오류가 단계 이름만 바꾸므로 영향이 미미하다. 6.7절의 점수는 P1의 조건 C 세션 총점이 부풀려진 영향이 있어 조건별 평균 비교 시 유의해야 한다. 6.8절에서는 13시 44분 세션의 긴 답변이 마무리 단계로 귀속되어 게이트에서 차단된 사례를 확장 집계 시 미탐으로 계상하였다. 6.9절의 조작 점검은 영향이 없다.

6.11 사용자 평가의 부재

본 실험에서 사용자 평가는 수행되지 않았다. 참가자 3명은 모두 시스템을 직접 개발한 팀원이며 세션 종료 후 사용성, 피드백 유용성, 면접관 현실감, 사회적 실재감에 대한 설문이나 인터뷰를 실시하지 않았다. 따라서 본 장의 모든 수치는 시스템 내부 로그에서 산출한 기술적 지표이며, 사용자가 이 시스템을 어떻게 경험했는지에 대한 자료는 존재하지 않는다.

그로 인한 결론의 제약은 네 가지이다. 첫째, 응답 지연이 실제 사용 경험을 얼마나 저해하는지 알 수 없다. 6.2절의 10.28s는 선행 연구 기준에 비추어 과도하나, 면접에서는 면접관이 답변을 숙고하는 침묵이 자연스럽게 해석될 여지가 있어 허용 한계가 더 클 가능성도 배제할 수 없다. 둘째, 동적 페르소나와 개입이 연습 효과에 기여하는지 알 수 없다. 3개 조건 실험의 본래 목적은 면접관의 반응 방식이 사용자 경험에 미치는 영향을 비교하는 것이었으나, 종속 변수가 시스템 내부 지표뿐이어서 조건 간 비교가 시스템이 조건별로 다르게 동작했다는 사실 확인에 그친다. 셋째, 피드백의 유용성이 검증되지 않았다. 넷째, 참가자가 개발자 본인이고 개입 발동 조건을 알고 있었으므로 일반 사용자와 동일한 방식으로 상호작용했다고 보기 어렵다.

향후 사용자 평가는 다음 설계로 수행할 것을 제안한다. 참가자는 시스템 개발에 관여하지 않은 취업 준비생 8명에서 12명으로 하고, 절차는 이력서 입력, 6분에서 8분의 면접 1세션 수행, 결과 화면 확인, 설문, 짧은 반구조화 인터뷰로 구성하여 총 30분 내외로 한다. 측정 도구는 관련 연구에서 널리 쓰이는 표준 척도를 사용하여 전반적 사용성은 시스템 사용성

척도를, 면접관의 사회적 실재감은 사회적 실재감 척도를, 에이전트 인상은 로봇 사회적 속성 척도의 온기와 유능성 하위 척도를 적용하고, 피드백 유용성과 면접관 현실감은 5점 리커트 문항으로 별도 구성한다. 자유 서술로는 가장 도움이 된 점, 가장 방해가 된 점, 개입이 적절했다고 느낀 정도를 수집한다. 참가자가 8명에서 12명이면 조건별 3명에서 4명의 피험자 간 설계가 가능하며, 피험자 내 설계는 1인당 3세션이 필요하여 부담이 크므로 조건 A와 조건 C의 2조건 비교로 축소하는 것이 현실적이다. 다만 현재 지연 수준에서는 조건 효과가 지연에 가려질 수 있으므로, 8장의 1단계와 2단계 개선을 적용해 지연을 6초대로 낮춘 뒤에 수행해야 한다.

6.12 평가 결과 종합

본 장의 평가 결과를 항목별로 요약하면 표 6.14과 같다.

표 6.14: 평가 항목별 결과 요약

평가 항목	결과	목표 대비
응답 지연	종단 지연 중앙값 9.95 s, 10 s 초과 턴 46.8%	미달
발화 종료 판정	평균 지연 2.91 s	미달
문장 스트리밍	다문장 대사에서 2.165 s(54.3%) 절감	효과 확인
개입 경로 지연	첫 발성까지 1.69 ~ 3.28 s	충족
음성 인식	CER 9.34%(충족), 전문 용어 인식률 82.4%(미달)	부분 충족
음성 피쳐	산출 성공률 98.1%	충족
영상 분석	얼굴 검출률 99.9%(충족), 실효 8.03 fps(미달)	부분 충족
제스처 피쳐	59구간 중 52구간이 0값	측정 실패
점수 산정	저품질 구간 순위는 재현, 고품질 인성 답변 3건 전부 0점	부분 실패
점수 체계	채점 결측률 27.8%, 무변별 항목 10개 중 4개	미달
개입 판정	긴 답변 트리거 100%, 이탈 판정기 33.3%, 종단 50%	부분 충족
실험 조작	페르소나 전이 성립률 66.7%	미달
시스템 안정성	세션 완주율 68.8%	미달
사용자 평가	미수행	—

평가 결과는 세 가지 층위로 요약된다.

첫째, 개별 구성 요소는 대체로 동작한다. 음성 합성은 초당 71 토큰의 처리량으로 안정적으로 동작하였고 문장 단위 스트리밍은 다문장 대사에서 54.3%의 지연을 절감하였다. 음성 인식은 완독 턴 기준 9.34%의 문자 오류율을, 영상 분석은 유효 세션에서 99.9%의 얼굴 검출률을 보였으며, 긴 답변 트리거는 완벽한 검출 성능을, 음성 피쳐는 98.1%의 산출 성공률을 기록하였다.

둘째, 요소를 결합한 종단 성능은 목표에 미달한다. 응답 지연은 측정된 모든 턴에서 허용 기준을 초과하였고 개입의 종단 정밀도와 재현율은 각각 50%에 그쳤다. 개별 요소가 나쁘지 않음에도 종단 성능이 나쁜 이유는 순차 처리 구조에서 각 단계의 지연이 누적되고 상류 단

계의 품질 저하가 하류에서 증폭되기 때문이며, 채점 해상도 문제가 페르소나 전이를 막고 그것이 다시 개입 기능을 무력화한 연쇄가 대표적이다.

셋째, 평가 체계 자체의 타당성에 구조적 문제가 있다. 10개 항목 중 4개가 변별력이 없고 1개는 측정에 실패했으며, 시선 항목은 측정 환경에 따라 총점의 절반에 해당하는 편차를 만들었고, 준비된 고품질 인성 답변은 3건 전부 0점을 받았다. 이 문제들은 하드웨어 개선이나 모델 교체로 해결되지 않으며 채점 프롬프트와 피쳐-점수 변환식의 재설계를 필요로 한다.

6.13 한계점의 정량적 근거

8장에 서술한 일곱 가지 한계점에 대응하는 측정 근거를 표 6.15에 정리한다.

표 6.15: 한계점과 측정 근거의 대응

한계점	측정 근거	절
대사 어조 일관성	페르소나 전이가 6세션 중 2세션에서 불성립, 연속 감정값이 5개 이산값만 사용	6.9
질문 생성 패턴 반복	9세션 전부에서 꼬리질문이 “구체적 사례·수치가 부족하다”는 지적 형태로 수렴. 직무가 서로 다른 6개 세션에서 “대용량 트래픽” 질문이 공통 등장	6.7
부분 전사 정확도	부분 전사 오류가 주제 이탈 오답으로 연결된 사례 확인, 판정기 정밀도 33.3%	6.4, 6.8
전문 용어 인식	전문 용어 인식률 82.4%, 영문 고유명사 72.7%, Kotlin은 3회 중 0회 정인식	6.4
제스처 표현 제한	손 사용 비율이 59구간 중 52구간에서 0값, 항목 점수가 9세션 중 7세션에서 2점 고정	6.6
점수 산정 단순성	점수값 5종만 산출, 채점 결측률 27.8%, 무변별 항목 4개, 고품질 인성 답변 3건 전부 0점	6.7
웹캠 환경 의존성	시선 유지 비율이 참가자 간 0.076 ~ 0.714, 총점 격차 14.0점 중 7.0점을 설명	6.6

여기에 더해 기존 한계점 목록에 없던 네 가지가 새로 확인되었다. 응답 지연이 모든 턴에서 허용 기준을 초과하며 답변 길이에 비례해 증가한다는 점, 침묵 임계값 단축 기능이 답변 종료 시점에 전혀 작동하지 않는다는 점, 제어 소켓 비정상 종료로 세션 완주율이 68.8%에 그친다는 점, 지연 전사 귀속 오류가 정상 종료 세션의 18.2%에서 발생하여 점수를 왜곡한다는 점이다. 개선 계획은 8장에 함께 기술한다.

제7장 프로젝트 추진 계획

7.1 구현 계획

표 7.1: 프로젝트 월별 구현 계획

개발 구분	세부 항목	5월	6월	7월	8월	9월
기획 및 설계	요구사항 확정 및 시스템 아키텍처 상세 설계					
	면접관 페르소나 및 면접 시나리오 설계					
환경 및 모듈 개발	Unity 면접장 공간 구축 및 3D 에셋 최적화					
	웹캠 기반 멀티모달 행동 데이터 수집 모듈 개발					
	STT·TTS 서버 구축					
	LLM 프롬프트 엔지니어링 및 컨텍스트 관리					
통합 및 기능 구현	WebSocket 기반 Unity·서버 실시간 연동					
	실시간 립싱크 및 연속형 페르소나 행동 패턴 구현					
	다각적 분석 기반 자동 피드백 리포트 시스템					
	면접관 실시간 개입 기능 구현					
최종 마무리	종합 시뮬레이션 테스트 및 최종 보고서 작성					
테스트 및 고도화	지연 시간 최적화 (수행 미흡)					

7.2 팀원별 역할 분담

표 7.2: 팀원별 주요 담당 업무

담당자	담당 영역	주요 작업
유재명	Unity 면접 환경	3D 면접장 공간 구축, Virtual Human 모델 제작, 면접 결과 화면 UI 제작
	서버 연동	비동기 FastAPI 서버 구축, Unity · 서버 간 WebSocket 전이중 통신 구현
	면접관 동작	uLipSync 기반 립싱크 동기화, 페르소나별 표정 · 제스처 애니메이션 바인딩
	멀티모달 · 개입 기능	웹캠 분석 연계, 면접관 실시간 개입
강저릭 어요솅드	자기소개 정보 처리	기업명 · 직무 · 경력 수준 · 기술 스택 · 강점 추출 및 구조화
	면접 진행 및 페르소나 제어	면접 단계별 지시문 · 턴 생성, 답변 점수 기반 페르소나 프롬프트 생성
	LLM 응답 및 예외 처리	JSON 응답 계약, 표정 · 제스처 ID 보정, 응답 재시도 · 폴백 처리
	면접 평가 및 피드백	종합 피드백 생성, STT 음성 특징 기반 피드백 고도화
강동요	음성 실행환경	Docker 기반 GPU 실행환경 구성, STT · TTS 워커 구축
	STT 처리	Whisper 기반 음성 전사, 발화 종료 및 음성 데이터 처리
	TTS 재생	Fish Speech 1.5 기반 음성 합성, 음성 스트리밍 및 Unity 오디오 버퍼 재생
	음성 특징 처리	발화 시간 · 침묵 횟수 · 평균 음량 추출, 음성 특징 서버 전송

제8장 결론 및 향후 계획

8.1 최종 구현 결과

본 과제에서는 PC 기반 Unity 3차원 면접 공간과 AI 백엔드를 연결하였다. 또한 STT, TTS, LLM 및 웹캠 분석 모듈을 하나의 면접 흐름으로 통합하였다. 사용자는 지원 기업과 직무 정보를 바탕으로 면접을 시작할 수 있으며, 시스템은 면접 단계와 대화 기록을 관리하면서 다음 질문과 면접관의 반응을 생성한다.

또한 답변 점수에 따라 면접관 페르소나가 변화하도록 구현하고, 음성·영상 정보를 이용한 10개 평가 항목과 최종 피드백 구조를 마련하였다. 개입 전후의 답변과 반응은 별도의 위상으로 기록하여 면접 흐름과 분석 결과를 함께 확인할 수 있다.

8.2 한계점

1. **면접관 대사 어조의 일관성:** 각 대사를 독립적으로 생성하는 과정에서 이전 대사의 전체 맥락과 말투가 충분히 유지되지 않을 수 있다. 그 결과 동일한 면접관 페르소나에서도 대사마다 존댓말의 정도, 말투, 반응의 강도가 달라지는 문제가 발생할 수 있다.
2. **질문 생성 패턴의 반복:** LLM이 이전 대화의 맥락을 반영하더라도 질문 주제와 표현이 유사하게 반복될 수 있다. 이로 인해 실제 면접에서 발생할 수 있는 다양한 질문과 답변 상황을 충분히 재현하기 어렵고, 반복 훈련의 효율이 떨어질 수 있다.
3. **부분 전사 정확도의 한계:** 현재 부분 전사는 발화 중에 생성되므로 최종 전사보다 정확도가 높지 않다. 이로 인해 부분 전사를 이용하는 발화 종료 및 개입 판단이 실제 발화 내용과 다르게 이루어질 가능성이 있다.
4. **전문 용어 인식의 한계:** 직무 관련 전문 용어는 일반적인 단어에 비해 STT 인식 정확도가 낮게 나타났다. 이로 인해 전사 결과에 기반한 답변 평가가 실제 답변 내용과 달라질 수 있다.

5. **제스처 표현의 제한:** 현재 면접관의 제스처 애니메이션은 표정 표현 등에 비해 적절한 리소스를 확보하기 어려워 표현 종류가 제한적이다.
6. **점수 산정의 단순성:** 일부 피쳐 기반 점수는 별도의 구조화된 평가 모델을 사용하지 않고, 해당 피쳐 값의 평균이나 미리 정한 상수를 이용한 사칙연산으로 계산한다. 따라서 실제 면접 능력을 정밀하게 반영하기에는 한계가 있다.
7. **웹캠 분석 환경 의존성:** 웹캠 기반 분석은 조명, 카메라 위치, 안경, 얼굴 방향에 영향을 받으므로 모든 환경에서 동일한 정확도를 보장하기 어렵다.

8.3 향후 개선 방향

향후에는 다양한 조명과 얼굴 방향에서 웹캠 분석의 신뢰도를 높이고, 캘리브레이션 실패를 자동으로 감지하는 기능을 보완할 예정이다. 또한 STT·TTS 모델의 경량화와 스트리밍 최적화를 통해 질문과 답변 사이의 지연 시간을 줄일 필요가 있다.

면접관 캐릭터 측면에서는 페르소나에 맞는 제스처와 상체 동작을 추가하고, 음성의 억양과 말하기 속도도 페르소나에 따라 조절할 수 있다. 평가 측면에서는 실제 면접관 또는 사용자 피드백을 기준으로 점수 산정식을 보완하고, 사용자가 이해하기 쉬운 결과 화면과 개선 가이드를 제공할 예정이다.

제A장 성능 측정용 대본

본 부록은 성능 측정에 사용된 면접 응답 대본이다. 대본과 실제 발화가 완전히 동일하지 않은 경우에는 대본 차이와 STT 오류를 구분하여 해석해야 한다.

참가자 응답 스크립트

이 대본은 조건 C 세션에서 사용한 기준 응답 스크립트이다. 회차별로 표현을 일부 바꾸더라도 단계별 답변의 길이와 구조는 유지한다.

1. 자기소개 (40 ~ 60초)

예상 질문: 자기소개를 부탁드립니다.

안녕하십니까. 웹과 앱 서비스 백엔드 개발, 그리고 여러 스타트업에서의 경험을 바탕으로 현재는 대규모 커머스 서비스의 백엔드 개발을 담당하고 있는 지원자입니다. Kotlin과 Java, Spring Boot를 주력으로 사용하고 있고, MySQL과 Redis, Kafka, Kubernetes 기반 환경에서 확장성과 유지보수성을 함께 고려한 아키텍처를 설계하고 운영해 온 경험이 있습니다. 특히 대규모 트래픽을 처리하는 과정에서 성능 최적화와 장애 대응을 반복적으로 경험하면서, 안정적인 서비스 운영이라는 게 결국 코드 하나보다 전체 구조를 보는 습관에서 나온다는 걸 느꼈습니다. 개인적으로는 블로그와 위키에 꾸준히 기술 글을 기록해왔고, 외부 리뷰어와 멘토링 활동을 통해서도 다른 개발자들과 계속 지식을 나누고 있습니다. 개발이라는 게 결국 비즈니스와의 긴밀한 커뮤니케이션 위에서 완성된다고 믿기 때문에, 앞으로도 팀과 조직 안에서 함께 성장하는 개발자가 되고 싶습니다. 잘 부탁드립니다.

약 55초 분량이다.

2. 기술 질문 (30 ~ 40초, 의도적 저품질)

예상 질문: 대규모 트래픽을 처리하면서 겪었던 성능 최적화 경험을 구체적으로 말씀해 주시겠어요?

네, 트래픽이 많이 몰릴 때는 아무래도 시스템에 부담이 가니까, 그런 부분들을 개선하려고 여러 가지로 노력했던 것 같습니다. 캐시라든지 여러 방법들을 써서 속도를 좀 더 빠르게 만들려고 했고, 팀 차원에서도 계속 모니터링하면서 문제 생기면 그때그때 대응했던 걸로 기억합니다. 전체적으로는 예전보다 많이 안정적으로 바뀌었다고 느꼈습니다.

일반론만 나열하고 구체적 지표·도구명·상황은 포함하지 않는 약 30초 분량의 답변이다.

3. 꼬리 질문 1 (20 ~ 30초, 의도적 저품질)

예상 질문: 방금 말씀하신 캐시 전략은 구체적으로 어떻게 구성하신 건가요?

아... 그 부분은 사실 제가 직접 설계했다기보다는, 팀에 계신 다른 분이 주로 담당 하셔서 정확한 구조까지는 잘 모르겠습니다. 저는 결과가 잘 나오는지 정도만 확인했던 것 같습니다.

약 20초 분량이다.

4. 꼬리 질문 2 (관련 답변 및 주제 이탈)

예상 질문: 그러면 장애 대응 과정에서 본인이 직접 맡았던 역할은 무엇이었나요?

관련 답변:

장애가 발생했을 때는 일단 로그를 확인하고, 어느 구간에서 문제가 생겼는지 원인을 좁혀나가는 작업을 했습니다. 팀원들과 같이 논의하면서 우선순위를 정하고 대응했던 기억이 있습니다.

주제 이탈:

그리고 보니 요즘 저녁에 퇴근하고 나서 러닝을 시작했는데, 확실히 체력이 있어 야 야근할 때도 집중력이 유지되는 것 같더라고요. 예전에는 그런 걸 잘 몰랐는데, 최근에 건강 관리에 관심이 생기면서 식단도 좀 신경 쓰고 있고, 주말에는 등산도 한 번씩 다니려고 하고 있습니다. 확실히 몸이 가벼워지니까 코드 리뷰할 때도 집중이 잘 되는 것 같아요. 아, 그리고 최근에 읽은 책 중에 조직 문화에 관한 책이 있었는데 거기서...

개입 후 재답변:

아, 네. 죄송합니다. 장애 대응에서는 주로 초기 원인 파악과 팀 커뮤니케이션 쪽을 맡았던 것 같습니다.

5. 인성 질문 (90초 이상, 긴 답변 개입 대상)

예상 질문: 본인의 강점, 혹은 협업할 때 중요하게 생각하는 가치는 무엇인가요?

제가 협업에서 가장 중요하게 생각하는 부분은 소통이라고 생각합니다. 서비스 개발이라는 게 혼자서 완성할 수 있는 게 아니고, 결국 개발과 비즈니스, 그리고 팀원들 사이의 긴밀한 커뮤니케이션 위에서 완성된다고 믿기 때문입니다. 그래서 저는 새로운 기능을 설계할 때도 혼자 결정하기보다는, 관련된 분들과 먼저 충분히 이야기를 나누고 방향을 맞춰가려고 하는 편입니다. 예를 들어 오픈소스 프로젝트에 참여하거나 외부 리뷰어 활동을 할 때도, 단순히 코드를 고치는 것보다는 왜 이런 방식으로 접근했는지를 설명하고, 상대방의 의견을 듣는 과정 자체를 중요하게 생각했습니다. 그런 과정에서 제가 미처 생각하지 못했던 관점을 배우는 경우가 많았고, 그게 결국 저 스스로도 성장하는 계기가 되었던 것 같습니다. 블로그나 위키에 기술 글을 꾸준히 기록해온 것도 비슷한 맥락인데요, 저 혼자만 알고 넘어가는 것보다는 다른 개발자들과 지식을 나누고, 그 과정에서 피드백을 받으면서 더 정확하게 이해하게 되는 경우가 많았습니다. 멘토링을 할 때도 마찬가지로, 제가 가진 지식을 일방적으로 전달하기보다는 상대방이 어떤 부분에서 막혔는지를 먼저 듣고, 그에 맞게 설명 방식을 조정하려고 노력했습니다. 이런 경험들을 통해서 저는 기술적인 역량 못지않게, 함께 일하는 사람들과 신뢰를 쌓고 원활하게 소통하는 능력이 장기적으로 더 큰 차이를 만든다는 걸 배웠습니다. 앞으로도 이런 태도를 바탕으로 팀과 조직에 기여하는 개발자가 되고 싶습니다.

약 95 ~ 100초 분량이다.

6. 마무리 (20 ~ 40초)

오늘 여러 질문 주셔서 감사합니다. 부족한 부분도 있었지만, 솔직하게 제 경험을 말씀드리려고 노력했습니다. 기회가 주어진다면 팀에 잘 녹아들어서 함께 성장하는 모습을 보여드리고 싶습니다. 감사합니다.

약 20초 분량이다.

제B장 LLM 프롬프트 전문

본 부록은 자기소개 정보 추출, 면접 턴 생성, 주제 이탈 판정, 개입 대사 생성, 답변 단독 채점 및 종료 피드백 생성에 사용되는 프롬프트를 정리한 것이다. 중괄호로 표시한 값은 실행 시 세션 정보와 이전 대화 기록으로 치환된다.

본 부록은 코드에서 실제로 사용하는 LLM 요청을 재현할 수 있도록 고정 지시문과 동적 입력 항목을 구분하여 정리한 것이다. 중괄호로 표시된 항목은 실행 시 세션 정보와 이전 대화 기록으로 치환된다.

B.1 자기소개 정보 추출

System: 사용자의 자기소개에서 면접에 필요한 정보를 정확히 추출하세요.

User: {self_intro} 내용을 입력한다.

Function Calling 함수명은 `extract_interview_info`이며, 다음 필드를 반환한다. `company_name`은 지원 기업명, `job_role`은 지원 직무, `experience_level`은 신입·주니어·중급·시니어 중 하나, `mentioned_skills`는 언급된 기술 스택의 배열, `key_strengths`는 지원자가 강조한 강점의 배열이다. `company_name`, `job_role`, `experience_level`은 필수 필드이다.

추출에 실패하거나 기업명·직무가 비어 있는 경우 Unity에서 전달한 기본값으로 보완한다.

B.2 면접 턴 생성

B.2.1 System 메시지

당신은 {company_name}의 {job_role} 채용 면접관이다.

지원자 정보: 경력 수준은 {experience_level}, 보유 기술은 {mentioned_skills}, 강조한 강점은 {key_strengths}, 이력서 요약은 {resume}이다.

답변을 그대로 인용하지 말고 핵심 키워드만 자연스럽게 언급한다. 단순히 구체적으로 설명해달라고 묻지 말고 기술적 근거와 트레이드오프를 질문한다. 경력 수준에 적합한 난이도로 조정하고 전문적이지만 위협적이지 않은 톤을 유지한다. 질문은 한 번에 하나만, 2 ~ 3문장 이내로 짧게 한다.

채점 기준은 다음과 같다. 0점은 무응답, 20점은 키워드만 나열한 답변, 40점은 단순 설명만 있는 답변, 60점은 구체적인 사례를 제시한 답변, 80점은 수치·성능 지표·비교 근거를 포함한 답변, 100점은 STAR 요소를 모두 갖춘 답변이다. 구간 사이 점수는 보간하되 40 ~ 60점에 임의로 몰아주지 않는다.

기술 질문 단계에서는 답변이 모호하면 빠진 근거·수치·구현 세부사항을 지적하고 압박 질문을 생성한다. 매 턴 문장 구조와 표현을 바꾼다. 그 밖의 단계에서는 직전 답변을 score 필드로만 채점하고 단계에 맞는 새 질문을 한다.

모든 대사는 자연스러운 한국어 존댓말로 작성한다. TTS로 출력되므로 마크다운·이모지·괄호 설명을 사용하지 않는다. 지정된 JSON 스키마 이외의 텍스트를 출력하지 않는다.

B.2.2 User 메시지

현재 단계는 {stage}, 이번 턴 과제는 {stage_task}, 추가 지시는 {extra_instruction}, 현재 페르소나는 {persona}이다. 직전 지원자 답변은 {user_answer}, 지금까지의 대화 기록은 {history}이다. 페르소나의 의미는 POSITIVE=안정감·미소, NEUTRAL=경청, NEGATIVE=압박·냉정이다.

순수 JSON으로만 응답하며 필드는 dialogue, score, score_reason, expression_id, gesture_id이다. 채점 대상이 아닌 단계의 score는 -1, 채점 대상의 score는 0 ~ 100의 정수이다. 표정과 제스처 ID는 현재 페르소나의 허용 목록 중 하나만 사용한다.

B.3 주제 이탈 판정

당신은 면접 답변이 질문 주제에서 벗어났는지 판정하는 판정기다. 반드시 보수적으로 판정하고 애매하면 이탈 아님(false)으로 판정한다. 답변 초반은 사례를 도입하는 중일 수 있으므로, 겉보기에 다른 화제 같아도 질문과 연결될 가능성이 있으면 이탈로 보지 않는다.

현재 질문은 {question}, 현재까지의 부분 전사는 {partial_answer}이다.

Function Calling 함수명은 `judge_off_topic`이며, `is_off_topic` 불리언 필드 하나를 반환한다.

B.4 개입 대사 생성

당신은 `{company_name}`의 `{job_role}` 채용 면접관이다. 지원자 보유 기술은 `{mentioned_skills}`이다. 지금 당신은 부정적인 태도 상태이며, 지원자의 답변 도중 말을 끊고 개입하려 한다. 대사는 원본 질문보다 짧게 2문장 이내로 작성한다. 부분 전사는 정확도가 낮을 수 있으므로 핵심 명사 한두 개만 짧게 인용한다. 단호한 어조를 쓰되 모욕적이지 않게 하며, 자연스러운 한국어 존댓말과 지정된 JSON만 사용한다.

개입 유형은 `{bargain_type}`, 사유는 `{reason}`, 원본 질문은 `{question}`, 지금까지의 답변은 `{partial_answer}`이다. 주제 이탈이면 이탈한 부분을 지적하고 원본 질문의 핵심만 짧게 다시 묻는다. 길이·침묵 개입이면 끊는 신호와 간결한 전환 문구만 작성한다.

출력 필드는 `dialogue`, `expression_id=5`, `gesture_id=8`이며, `score`와 `score_reason`은 포함하지 않는다.

B.5 답변 단독 채점

당신은 면접 답변을 채점하는 채점관이다. 대사나 질문은 만들지 않고 채점만 한다. 0점은 무응답, 20점은 키워드만 나열한 답변, 40점은 근거 없는 단순 설명, 60점은 구체적 사례, 80점은 수치·성능 지표·비교 근거를 포함한 답변, 100점은 STAR 요소를 모두 갖춘 답변이다. 구간 사이 점수는 보간한다. 답변이 중간에 끊겼다면 해당 시점까지의 내용만 근거로 채점한다.

질문은 `{question}`, 답변은 `{answer}`이다. Function Calling 함수명은 `score_answer`이며 `score`와 `score_reason`을 반환한다.

B.6 종료 피드백 생성

당신은 면접 코치다. 아래 면접 기록을 바탕으로 건설적 피드백을 한국어로 작성한다. JSON으로만 응답한다.

기업·직무는 `{company}` / `{job_title}`, 평균 발화시간은 `{avg_speaking_time}`,

총 침묵 횟수는 {total_pauses}, 단계별 점수는 {stage_scores}, 전체 대화 기록은 {transcript}이다.

전체 답변 텍스트를 분석하여 필러 단어와 말더듬을 평가하고 filler_score(0 ~ 10)를 매긴다. 필러가 적을수록 높은 점수이다. 답변 내용의 충실도와 밀도를 평가하여 density_score(0 ~ 10)를 매긴다. 출력 필드는 strengths, improvements, summary, filler_score, density_score이다.

제C장 대면 실험 응답 대본

본 부록은 6장의 대면 실험에서 P1과 P3가 사용한 응답 대본이다. P2의 대본은 부록 A와 동일하다. 세 대본은 모두 단계별 답변의 길이와 구조를 동일하게 맞추어 작성하였으며, 세 조건에서 같은 대본을 사용하였다.

P1(넥슨 게임 클라이언트 프로그래머) 대본

1. 자기소개

질문: 지원 동기를 포함해 자기소개를 부탁드립니다.

네, 안녕하세요. 유니티 기반 게임 클라이언트 프로그래머로 2년 정도 개발해 온 지원자입니다. 1인 개발 프로젝트를 진행하면서 기획과 프로그래밍, 아트를 모두 담당한 경험이 있고, Photon을 사용해서 멀티플레이 게임을 개발한 경험도 있습니다. 대표적으로 8번 출구를 모작한 지하 10층이라는 싱글플레이 게임을 만들었고, 냅코 대전쟁을 모작한 풍림화산 전쟁이라는 멀티플레이 게임을 개발했습니다. 넥슨의 게임 클라이언트 프로그래머로 지원하게 되었습니다. 잘 부탁드립니다.

2. 기술 질문 (30 ~ 40초, 의도적 저품질)

질문: 멀티플레이 구현 경험에 대해 구체적으로 말씀해 주시겠어요?

네, 풍림화산 전쟁에서 Photon을 사용해서 멀티플레이를 구현했습니다. 룸을 만들고 플레이어들이 입장해서 동기화되는 방식으로 했고, RPC랑 동기화 컴포넌트를 사용했습니다. 큰 문제 없이 잘 동작했습니다. 최적화는 유니티에서 제공하는 기능들을 사용해서 처리했고 오브젝트 풀링도 적용했습니다.

3. 꼬리 질문 1 (20 ~ 30초, 의도적 저품질)

질문: 동기화 방식은 어떤 기준으로 선택하셨나요?

음, 그 부분은 깊게 파고들지는 않았습시다. 유니티에서 기본으로 제공하는 걸 그대로 썼고, 테스트해 봤을 때 문제가 없어서 그대로 갔습시다. 성능을 따로 측정해보지는 않았습시다. 정확히 어떤 값이었는지는 기억이 나지 않습시다.

4. 꼬리 질문 2 (관련 답변 및 주제 이탈)

질문: 그 과정에서 발생한 문제를 어떻게 해결하셨나요?

관련 답변:

네, 그 부분은 개발하면서 팀 프로젝트를 할 때도 비슷한 상황이 있었는데요, 저는 주로 클라이언트 쪽을 맡아서 진행했었고, 그때도 일정이 좀 빡빡했었습니다.

주제 이탈:

그런데 혹시 어제 축구 경기 보셨어요? 후반전에 역전골 들어가는 거 보고 진짜 소리 질렀거든요. 저는 원래 주말마다 경기를 챙겨 보는 편인데 이번 시즌은 유독 재미있는 것 같습니다. 지난 주말에도 친구들이랑 같이 보러 갔었는데 분위기가 정말 좋았습니다.

개입 후 재답변:

아, 죄송합니다. 팀 프로젝트에서는 서로 담당이 나뉘어 있어서 진행 상황을 자주 공유하는 게 중요했습니다. 저는 클라이언트를 맡았고, 서버 쪽과 인터페이스를 먼저 맞추고 나서 각자 작업하는 방식으로 진행했습니다.

5. 인성 질문 (90초 이상)

질문: 협업 과정에서 갈등을 겪은 경험이 있다면 말씀해 주세요.

네, 협업할 때 갈등이 있었던 경험이라면 졸업과제를 하면서 있었던 일이 떠오르는데요, 저희가 세 명이서 팀을 이뤄서 진행을 했었고, 각자 담당 영역이 달랐기 때문에 처음에는 각자 알아서 하면 되겠다고 생각했었는데, 막상 통합을 하려고 보니까 서로 가정하고 있던 인터페이스가 달라서 맞지 않는 부분들이 계속 나왔고, 그러다 보니까 누가 맞춰야 하는지를 두고 의견이 갈렸었는데, 저는 클라이언트를 맡고 있었기 때문에 서버 쪽 형식에 맞추는 게 맞다고 생각을 했었고, 반대로 상대방은 클라이언트가 이미 구현이 되어 있으니까 서버가 맞추는 게 빠르다고 이야기를 했었어서, 서로 자기 쪽 작업량이 적어지는 방향으로 이야기가 흘러가는 상황이 되었고, 그때 제가 느꼈던 건 이걸 감정적으로 끌고 가면 안 되겠다는

거였는데, 왜냐하면 남은 일정이 얼마 없었고 이런 걸로 며칠을 쓰면 결국 둘 다 손해라는 생각이 들어서, 일단 각자 어느 정도 작업이 필요한지를 먼저 적어 보자고 제안을 했었고, 실제로 적어 놓고 보니까 생각보다 차이가 크지 않아서 결국 제가 맞추는 쪽으로 정리가 되었었는데, 그 과정에서 배운 건 갈등 자체가 문제가 아니라 기준 없이 이야기하는 게 문제라는 거였고, 그 이후로는 작업을 시작하기 전에 인터페이스를 먼저 문서로 정해 놓고 들어가는 습관이 생겼고, 실제로 그다음부터는 비슷한 문제가 거의 없었습니다.

6. 마무리 (20 ~ 40초)

네, 오늘 부족한 부분을 많이 느꼈습니다. 기회를 주신다면 더 준비해서 잘 해내고 싶습니다. 감사합니다.

P3(업스테이지 AI 엔지니어) 대본

1. 자기소개

질문: 지원 동기를 포함해 자기소개를 부탁드립니다.

안녕하십니까, 저는 자연어처리를 중심으로 공부해온 AI 엔지니어 지망생입니다. 학부 때부터 파이썬을 주력으로 다뤘고, 텍스트 데이터를 다루는 문제에 관심이 많아서 자연어처리 쪽으로 진로를 정하게 됐습니다. PyTorch로 텍스트 분류 모델을 처음부터 학습시켜본 경험이 있고, Hugging Face의 사전학습 모델을 파인 튜닝해서 감성 분석 프로젝트를 완성한 적도 있습니다. 최근에는 RAG 구조를 직접 구현해보면서 벡터 데이터베이스를 연동하는 작업을 진행하고 있는데, 이 과정에서 검색과 생성을 결합하는 문제에 흥미를 느껴서 이 분야로 계속 성장하고 싶다는 확신이 들었습니다. 실제 서비스 규모의 데이터를 다뤄보며 역량을 더 키우고 싶어서 지원하게 됐습니다.

2. 기술 질문 (30 ~ 40초, 의도적 저품질)

질문: 모델 학습 과정에서 하이퍼파라미터는 어떻게 조정하셨나요?

네, 저도 비슷한 상황에서 나름대로 신경 써서 접근했던 것 같습니다. 여러 가지 방법을 고려해보고 그중에서 적절해 보이는 방식으로 진행했는데, 결과적으로는 나쁘지 않게 나왔던 걸로 기억합니다. 다만 정확한 수치나 세부적인 설정값까지는 기억이 잘 안 나서 전체적인 흐름 위주로만 말씀드릴 수 있을 것 같습니다.

3. 꼬리 질문 1 (20 ~ 30초, 의도적 저품질)

질문: 어떤 기준으로 그 방식을 선택하셨는지 설명해 주시겠어요?

음, 지금 여쭙보신 부분은 제가 자세히는 잘 모르겠습니다. 그냥 어디선가 참고해서 설정값 정도만 가져다 쓰고, 결과가 그럴듯하게 나오는지 확인만 해봤던 것 같아요. 원리까지 깊게 파고들지는 못했습니다.

4. 꼬리 질문 2 (관련 답변 및 주제 이탈)

질문: 대용량 데이터 처리나 응답 속도는 어떻게 고려하셨나요?

관련 답변:

그 부분도 비슷한 방식으로 접근했던 것 같은데요, 상황에 맞춰서 이런저런 시도를 해보면서 조정했습니다. 처음에 생각했던 것보다 고려해야 할 부분들이 좀 있어서, 몇 번 방법을 바꿔가면서 진행했던 기억이 있습니다.

주제 이탈:

아, 근데 오늘 날씨 많이 덥지 않나요? 오는 길에 좀 덥더라고요. 요즘 계속 이런 날씨가 이어져서 다니기가 쉽지 않은 것 같습니다.

개입 후 재답변:

아, 네, 죄송합니다. 그 부분은 딱히 특별한 건 없었고 그냥 무난하게 넘어갔던 것 같습니다.

5. 인성 질문 (90초 이상)

질문: 협업 과정에서 의견이 달랐던 경험이 있다면 말씀해 주세요.

네, 협업하면서 있었던 경험을 말씀드리면, 사이드 프로젝트로 감성 분석 모델을 만들 때였는데요, 팀원 한 명이 데이터 라벨링 기준을 저랑 다르게 이해하고 있어서 중간에 데이터 품질 문제가 발견됐던 적이 있습니다. 처음엔 서로 자기 기준이 맞다고 생각해서 의견 차이가 좁혀지지 않았고, 저는 라벨링 가이드라인을 더 세밀하게 문서화해야 한다고 생각했는데, 팀원은 지금 진행 속도가 더 중요하다고 봤습니다. 그래서 일단 감정적으로 부딪히기보다는, 실제로 라벨링이 걸린 샘플들을 같이 모아서 눈으로 직접 비교해보자고 제안했습니다. 그렇게 스무 개 정도 샘플을 뽑아서 같이 검토해보니, 저희 둘 다 애매하다고 느끼는 경계 케이스들이

생각보다 많다는 걸 확인할 수 있었고, 그 지점에서 오히려 대화가 더 쉽게 풀렸습니다. 결국 애매한 케이스는 별도 카테고리로 분리하고, 명확한 케이스만 우선 라벨링해서 진행 속도도 유지하면서 품질 문제도 줄이는 절충안을 같이 만들었습니다. 이 경험을 통해서 의견이 다를 때 누가 옳은지 논쟁하기보다는, 판단 근거가 되는 실제 데이터를 같이 보면서 이야기하는 게 훨씬 생산적이라는 걸 배웠습니다. 이후 프로젝트에서도 의견이 갈리는 상황이 생기면 먼저 근거 자료부터 같이 살펴보는 습관이 생겼고, 그게 팀 내에서 불필요한 갈등을 줄이는 데 도움이 됐던 것 같습니다.

6. 마무리 (20 ~ 40초)

특별히 더 여쭙보고 싶은 건 없고, 오늘 좋은 질문들 주셔서 감사했습니다. 저의 부족한 부분들도 잘 파악할 수 있었던 시간이었던 것 같습니다.

제D장 대면 실험 세션 목록과 결과

본 부록은 6장의 분석에 사용한 세션 목록과 세션별 결과를 정리한 것이다.

전체 실행 목록

2026년 9월 4일에 기록된 16회의 세션 실행과 분석 대상 여부는 표 D.1과 같다.

표 D.1: 대면 실험에서 실행된 전체 세션(16회)

번호	종료 시각	조건	참가자	지속(초)	종료 상태	개입	분석
1	12:55:10	C	P1	24.6	연결 끊김	0	제외
2	13:12:48	C	P1	210.8	정상	0	제외
3	13:15:39	A	P1	31.6	연결 끊김	0	제외
4	13:20:59	A	P1	200.8	연결 끊김	0	제외
5	13:25:53	A	P1	277.1	정상	0	포함
6	13:35:37	B	P2	382.3	정상	0	포함
7	13:44:10	C	P3	335.9	정상	0	제외
8	13:53:45	C	P3	305.6	정상	2	포함
9	14:01:31	B	P1	296.2	정상	0	포함
10	14:11:26	C	P2	479.2	연결 끊김	0	제외
11	14:18:41	C	P2	371.9	정상	0	포함
12	14:32:09	B	P3	287.7	정상	0	포함
13	14:37:08	C	P1	182.7	연결 끊김	0	제외
14	14:42:02	C	P1	276.6	정상	2	포함
15	14:50:58	A	P2	379.7	정상	0	포함
16	14:57:11	A	P3	262.7	정상	0	포함

제외된 7회의 사유는 다음과 같다. 1번, 3번, 4번, 10번, 13번은 각각 기술 질문, 마무리, 인성 질문 단계에서 Unity와 백엔드 사이의 제어 소켓이 비정상 종료되어 최종 피드백이 산출되지 않았다. 2번은 정상 종료되었으나 웹캠이 프레임을 공급하지 못하여 실효 프레임률이 1.1 fps, 얼굴 검출률이 0%로 캘리브레이션에 실패하였고, 외부 소음으로 음성 인식이 오작동하여 답변 프로토콜이 수행되지 못하였다. 7번은 정상 종료되었으나 인성 질문 답변이 마무리 단계에 귀속되는 결함이 발생하여 재실행하였다.

유효 9세션의 최종 결과

유효 9세션의 항목별 점수와 총점은 표 D.2와 같다. 각 값은 세션 JSON의 최종 피드백 값이며, 실험 당시 촬영한 결과 화면 캡처 9장과 일치함을 확인하였다.

표 D.2: 유효 9세션의 최종 결과(각 항목 0 ~ 10점)

참가자	조건	시선	손	자세	표정	음량	속도	길이	필러	정확도	반응	총점
P1	A	6	8	9	10	9	4	5	7	2	9	69
P1	B	6	3	10	10	9	4	6	8	3	10	69
P1	C	10	2	10	10	9	5	5	7	2	10	70
P2	A	5	2	10	10	9	1	6	8	2	10	63
P2	B	10	2	10	10	9	0	6	8	4	10	69
P2	C	7	2	10	10	9	2	7	7	4	10	68
P3	A	1	2	10	10	9	3	5	6	3	10	59
P3	B	0	2	10	10	9	2	5	5	1	10	54
P3	C	0	2	10	10	9	2	4	5	1	10	53

세션별 단계 점수와 개입 기록

단계별 LLM 답변 점수와 개입 발생 여부는 표 D.3와 같다. 표시된 값은 해당 단계의 답변에 대해 산출된 점수이며, 빗금은 점수가 산출되지 않은 결측을 의미한다.

표 D.3: 유효 9세션의 단계별 답변 점수와 개입 기록

참가자	조건	기술 질문	꼬리 1	꼬리 2	인성 질문	페르소나 전이	개입
P1	A	40	40	0	0	없음	—
P1	B	40	40	—	0	1회	—
P1	C	30	20	0	—	1회	주제 이탈 1, 긴 답변 1
P2	A	45	0	—	—	없음	—
P2	B	40	40	—	—	없음	—
P2	C	40	40	—	—	없음	미발동(페르소나 게이트)
P3	A	40	20	20	—	없음	—
P3	B	40	0	0	0	1회	—
P3	C	30	0	0	—	1회	주제 이탈 2

표에서 확인할 수 있듯이 산출된 점수는 0, 20, 30, 40, 45의 다섯 값에 집중되어 있고, 36개 채점 대상 턴 중 10개가 결측이다. 또한 조건 C의 세 세션 중 P2의 세션만 개입이 한번도 발동하지 않았는데, 이 세션은 기술 질문과 꼬리질문 1이 모두 40점을 받아 페르소나가 중립을 유지한 유일한 조건 C 세션이다.

참고문헌

- [1] Deeksha Adiani, Aaron Itzkovitz, Dayi Bian, Harrison Katz, Michael Breen, et al. Career interview readiness in virtual reality (CIRVR): A platform for simulated interview training for autistic individuals and their employers. *ACM Transactions on Accessible Computing*, 15(1):1–28, 2022.
- [2] Valentin Bazarevsky, Ivan Grishchenko, Karthik Raveendran, Tyler Zhu, Fan Zhang, and Matthias Grundmann. Blazepose: On-device real-time body pose tracking. *arXiv preprint arXiv:2006.10204*, 2020.
- [3] Edresson Casanova, Kelly Davis, Eren Gölge, Görkem Gökner, Iulian Gulea, Logan Hart, Aya Aljafari, Joshua Meyer, Reuben Morais, Samuel Olayemi, and Julian Weber. XTTS: A massively multilingual zero-shot text-to-speech model. *arXiv preprint arXiv:2406.04904*, 2024.
- [4] Groq. Your data in groqcloud. <https://console.groq.com/docs/your-data>, 2026. Groq API 데이터 처리 및 보존 정책, accessed 2026-09-14.
- [5] Mohammed Ehsan Hoque, Matthieu Courgeon, Jean-Claude Martin, Bilge Mutlu, and Rosalind W. Picard. MACH: My automated conversation coach. In *Proceedings of the 2013 ACM International Joint Conference on Pervasive and Ubiquitous Computing*, pages 697–706, 2013.
- [6] Yury Kartynnik, Artsiom Ablavatski, Ivan Grishchenko, and Matthias Grundmann. Real-time facial surface geometry from monocular video on mobile gpus. *arXiv preprint arXiv:1907.06724*, 2019.
- [7] Shijia Liao, Yuxuan Wang, Tianyu Li, Yifan Cheng, Ruoyi Zhang, Rongzhi Zhou, and Yijin Xing. Fish-speech: Leveraging large language models for advanced multilingual text-to-speech synthesis. *arXiv preprint arXiv:2411.01156*, 2024.
- [8] Camillo Lugaresi, Jiuqiang Tang, Hadon Nash, Chris McClanahan, Esha Uboweja, Michael Hays, Fan Zhang, Chuo-Ling Chang, Ming Guang Yong, Juhyun Lee, Wan-Teh Chang, Wei Hua, Manfred Georg, and Matthias Grundmann. Mediapipe: A framework for building perception pipelines. *arXiv preprint arXiv:1906.08172*, 2019.
- [9] Jakob Nielsen. *Usability Engineering*. Morgan Kaufmann, San Francisco, CA, 1993. 응답 시간 0.1초, 1초, 10초 한계에 관한 지침.

- [10] OpenAI. Data controls in the openai platform. <https://developers.openai.com/api/docs/guides/your-data>, 2026. OpenAI API 데이터 처리 및 보존 정책, accessed 2026-09-14.
- [11] Alec Radford, Jong Wook Kim, Tao Xu, Greg Brockman, Christine McLeavey, and Ilya Sutskever. Robust speech recognition via large-scale weak supervision. In *Proceedings of the 40th International Conference on Machine Learning*, volume 202 of *Proceedings of Machine Learning Research*, pages 28492–28518. PMLR, 2023.
- [12] Gabriel Skantze. Turn-taking in conversational systems and human-robot interaction: A review. *Computer Speech & Language*, 67:101178, 2021.
- [13] Yoodli. Practice with Yoodli: Interview roleplay and feedback. <https://support.yoodli.ai/en/articles/9550465-practice-with-yoodli>, 2026. 상용 AI 면접 연습 서비스, accessed 2026-09-14.